



Cyprus
University of
Technology

Σχολή Μηχανικής και
Τεχνολογίας

Διπλωματική Εργασία

**ΠΕΙΡΑΜΑΤΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ FOREX:
ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ ΤΩΝ ΜΟΝΤΕΛΩΝ LAG
LLAMA ΚΑΙ LSTM ΓΙΑ ΤΗΝ ΠΡΟΒΛΕΨΗ
ΣΥΝΑΛΛΑΓΜΑΤΙΚΩΝ ΙΣΟΤΙΜΙΩΝ**

ΠΡΩΤΟΠΑΠΑ ΝΙΚΟΛΕΤΤΑ

Λεμεσός, Δεκέμβριος 2025

ΤΕΧΝΟΛΟΓΙΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΚΥΠΡΟΥ

ΣΧΟΛΗ ΜΗΧΑΝΙΚΗΣ ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ

ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ

ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΚΗΣ

Διπλωματική Εργασία

ΠΕΙΡΑΜΑΤΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ FOREX:
ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ ΤΩΝ ΜΟΝΤΕΛΩΝ LAG LLAMA
ΚΑΙ LSTM ΓΙΑ ΤΗΝ ΠΡΟΒΛΕΨΗ ΣΥΝΑΛΛΑΓΜΑΤΙΚΩΝ
ΙΣΟΤΙΜΙΩΝ

ΠΡΩΤΟΠΑΠΑ ΝΙΚΟΛΕΤΤΑ

Επιβλέπων Καθηγητής

Δρ. Σωτήριος Χατζής

Λεμεσός, Δεκέμβριος 2025

Πνευματικά δικαιώματα

Copyright © Πρωτοπαπά Νικολέττα, 2025

Με επιφύλαξη παντός δικαιώματος.

Η έγκριση της παρούσας πτυχιακής εργασίας από το Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών δεν υποδηλώνει κατ' ανάγκην αποδοχή των απόψεων του συγγραφέα εκ μέρους του Τμήματος

ΠΕΡΙΛΗΨΗ

Η παρούσα πτυχιακή εργασία εξερευνά μεθόδους πρόβλεψης συναλλαγματικών ισοτιμιών στην αγορά συναλλάγματος (Forex), έναν τομέα που χαρακτηρίζεται από έντονη μεταβλητότητα και πολυπλοκότητα. Ο κύριος στόχος είναι η σύγκριση δύο προηγμένων προσεγγίσεων μηχανικής μάθησης για την πρόβλεψη χρονοσειρών: του μοντέλου Long Short-Term Memory (LSTM) και του μοντέλου Lag-Llama. Το Lag-Llama, ένα σύγχρονο foundation model βασισμένο στην αρχιτεκτονική Transformer, έχει σχεδιαστεί ειδικά για την πρόβλεψη χρονοσειρών.

Για την εκπαίδευση και αξιολόγηση των μοντέλων χρησιμοποιήθηκαν ημερήσια ιστορικά δεδομένα συναλλαγματικών ισοτιμιών που εκτείνονται σε πολλά έτη. Η μεθοδολογία περιλάμβανε προεπεξεργασία και κανονικοποίηση των δεδομένων, διαχωρισμό του συνόλου δεδομένων σε υποσύνολα εκπαίδευσης και δοκιμής, καθώς και αξιολόγηση της απόδοσης των μοντέλων με τη χρήση καθιερωμένων μετρικών, όπως το Μέσο Απόλυτο Σφάλμα (MAE), το Τετραγωνικό Μέσο Ριζικό Σφάλμα (RMSE) και το Μέσο Απόλυτο Ποσοστιαίο Σφάλμα (MAPE).

Τα αποτελέσματα δείχνουν ότι, στα εξεταζόμενα σενάρια, το μοντέλο LSTM παρουσίασε χαμηλότερα σφάλματα (MAE, RMSE, MAPE) σε σχέση με το Lag-Llama στη διαδικασία πρόβλεψης zero-shot. Δεδομένου ότι δεν ήταν δυνατή η πλήρης διαδικασία fine-tuning για το Lag-Llama, η απόδοσή του δεν μπόρεσε να αξιολογηθεί ολοκληρωμένα. Παρ' όλα αυτά, η μελέτη αναδεικνύει τη σημαντική δυναμική των foundation models στην πρόβλεψη χρηματοοικονομικών χρονοσειρών και υποδεικνύει ότι το Lag-Llama ενδέχεται να επιτύχει καλύτερες επιδόσεις υπό κατάλληλη διαδικασία προσαρμογής. Συνολικά, η έρευνα φωτίζει τόσο τις προκλήσεις όσο και τα πλεονεκτήματα της χρήσης σύγχρονων μεθόδων βαθιάς μάθησης για την ανάλυση και πρόβλεψη της αγοράς συναλλάγματος.

Λέξεις κλειδιά: Χρονοσειρές, Forex, LSTM, Lag-Llama, Foundation Models, Πρόβλεψη

ABSTRACT

This thesis investigates forecasting methods for exchange rates in the foreign exchange (Forex) market, a domain characterised by significant volatility and complexity. The primary objective is to compare two advanced machine learning approaches for time-series forecasting: the Long Short-Term Memory (LSTM) model and the Lag-Llama model. Lag-Llama, a recent foundation model based on the Transformer architecture, is specifically designed for time-series prediction.

Daily historical exchange-rate data spanning several years were utilised for model training and evaluation. The methodology comprised data preprocessing and normalisation, partitioning the dataset into training and testing subsets, and evaluating model performance using established metrics, including Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), and Mean Absolute Percentage Error (MAPE).

The results indicate that, across the tested scenarios, the LSTM model had lower error rates (MAE, RMSE, MAPE) than Lag-Llama in zero-shot forecasting. Since a full fine-tuning process for Lag-Llama was not possible, its performance could not be fully evaluated. Still, the study shows that foundation models have strong potential for financial time-series forecasting and suggests that Lag-Llama might perform better with proper fine-tuning. This research highlights both the challenges and advantages of using modern deep learning methods to analyse and predict foreign exchange markets.

Keywords: Time Series, Forex, LSTM, Lag-Llama, Foundation Models, Forecasting

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

| | |
|---|-----------|
| ΚΥΡΙΩΣ ΚΕΙΜΕΝΟ ΤΗΣ ΕΡΓΑΣΙΑΣ | 1 |
| 1 ΕΙΣΑΓΩΓΗ | 2 |
| 1.1 ΚΙΝΗΤΡΟ..... | 2 |
| 1.2 ΣΚΟΠΟΣ | 4 |
| 1.3 ΕΡΕΥΝΗΤΙΚΑ ΕΡΩΤΗΜΑΤΑ | 5 |
| 2 ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ ΚΑΙ ΑΝΑΣΚΟΠΗΣΗ ΒΙΒΛΙΟΓΡΑΦΙΑΣ | 7 |
| 2.1 ΙΔΙΑΙΤΕΡΟΤΗΤΕΣ ΧΡΗΜΑΤΟΟΙΚΟΝΟΜΙΚΩΝ ΧΡΟΝΟΣΕΙΡΩΝ | 7 |
| 2.2 ΚΛΑΣΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΠΡΟΒΛΕΨΗΣ ΧΡΟΝΟΣΕΙΡΩΝ ΚΑΙ ΠΕΡΙΟΡΙΣΜΟΙ | 9 |
| 2.3 ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ ΓΙΑ ΠΡΟΒΛΕΨΗ ΧΡΟΝΟΣΕΙΡΩΝ – ΜΟΝΤΕΛΟ LSTM | |
| 10 | |
| 2.4 FOUNDATION MODELS ΚΑΙ ΑΡΧΙΤΕΚΤΟΝΙΚΗ TRANSFORMER ΓΙΑ ΧΡΟΝΟΣΕΙΡΕΣ | 12 |
| 2.5 ΤΟ ΜΟΝΤΕΛΟ LAG – LLAMA: FOUNDATION MODEL ΕΞΕΙΔΙΚΕΤΜΕΝΟ ΓΙΑ ΧΡΟΝΟΣΕΙΡΕΣ | 14 |
| 2.6 ΕΠΙΛΟΓΗ ΕΡΕΥΝΗΤΙΚΗΣ ΠΡΟΣΕΓΓΙΣΗΣ..... | 17 |
| 3 ΔΕΔΟΜΕΝΑ ΚΑΙ ΕΞΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ (EDA)..... | 19 |
| 3.1 ΠΗΓΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΧΑΡΑΚΤΗΡΙΣΤΙΚΑ ΤΟΥ FOREX DATASET..... | 19 |
| 3.2 ΕΞΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ | 21 |
| 3.2.1 Μακροχρόνιες τάσεις των συναλλαγματικών ισοτημιών | 21 |
| 3.2.2 Ημερήσιες αποδόσεις και μεταβλητότητα | 23 |
| 3.2.3 Συγχέτιση μεταξύ ζευγών νομισμάτων | 27 |
| 3.2.4 Ιδιομορφίες της κατανομής αποδόσεων | 27 |
| 3.2.5 Σύνοψη ευρημάτων της Εξερευνητικής Ανάλυσης | 28 |

| | | |
|----------|--|-----------|
| 4 | ΜΕΘΟΔΟΛΟΓΙΑ | 30 |
| 4.1 | ΕΠΙΚΣΟΠΗΣΗ ΜΕΘΟΔΟΛΟΓΙΑΣ..... | 30 |
| 4.2 | ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΚΑΙ ΚΑΘΑΡΙΣΜΟΣ ΔΕΔΟΜΕΝΩΝ | 32 |
| 4.3 | ΔΙΑΧΩΡΙΣΜΟΣ ΕΚΠΑΙΔΕΥΣΗΣ – ΕΛΕΓΧΟΥ (TRAIN – TEST SPLIT) | 33 |
| 4.4 | ΑΡΧΙΤΕΚΤΟΝΙΚΗ ΚΑΙ ΕΚΠΑΙΔΕΥΣΗ LSTM | 34 |
| 4.5 | ΡΥΘΜΙΣΗ ΚΑΙ ΔΙΑΔΙΚΑΣΙΑ ΠΡΟΒΛΕΨΗΣ ΜΕ LAG-LLAMA | 36 |
| 4.6 | ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ | 37 |
| 4.7 | ΠΕΙΡΑΜΑΤΙΚΟΣ ΣΧΕΔΙΑΣΜΟΣ..... | 38 |
| 5 | ΑΠΟΤΕΛΕΣΜΑΤΑ | 41 |
| 5.1 | ΣΥΝΟΠΤΙΚΗ ΠΑΡΟΥΣΙΑΣΗ ΤΩΝ ΠΕΙΡΑΜΑΤΙΚΩΝ ΑΠΟΤΕΛΕΣΜΑΤΩΝ ... | 41 |
| 5.2 | ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΜΕ LSTM | 46 |
| 5.3 | ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ LAG – LLAMA..... | 48 |
| 5.3.1 | Αποτελέσματα Πρόβλεψης Lag – Llama με Zero – Short..... | 48 |
| 5.3.2 | Αποτελέσματα Πρόβλεψης Lag – Llama με Fine – Tuning | 55 |
| 5.4 | ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ..... | 56 |
| 6 | ΣΥΖΗΤΗΣΗ..... | 59 |
| 7 | ΣΥΜΠΕΡΑΜΣΑΤΑ..... | 62 |
| 8 | ΒΙΒΛΙΟΓΡΑΦΙΑ..... | 65 |

ΑΠΟΔΟΣΗ ΟΡΩΝ

Στην περίπτωση χρήσης ορολογίας από ξενόγλωσση βιβλιογραφία, αναφέρεται η απόδοση στην ελληνική η οποία θεωρείται περισσότερο δόκιμη. Για παράδειγμα:

| | |
|----------|--------------|
| Data | Δεδομένα |
| Metadata | Μεταδεδομένα |

ΚΥΡΙΩΣ ΚΕΙΜΕΝΟ ΤΗΣ ΕΡΓΑΣΙΑΣ

Το κύριο μέρος της παρούσας εργασίας εισάγει το κεντρικό ερευνητικό ερώτημα και αναπτύσσει την κύρια επιχειρηματολογία. Παρέχει μια συγκριτική ανάλυση δύο μεθόδων πρόβλεψης χρονοσειρών, του μοντέλου Long Short-Term Memory (LSTM) και του foundation model Lag-Llama, για την πρόβλεψη συναλλαγματικών ισοτιμιών. Η ενότητα αυτή παρουσιάζει το θεωρητικό υπόβαθρο, τη μεθοδολογική προσέγγιση, τις διαδικασίες προετοιμασίας των δεδομένων και τα αποτελέσματα της ανάλυσης.

Η συζήτηση συνθέτει τα αποτελέσματα με ευρήματα της πρόσφατης έρευνας, αναδεικνύοντας τις τρέχουσες τάσεις και εντοπίζοντας τα κενά που εξακολουθούν να υπάρχουν. Η ανάλυση προσφέρει μία ολοκληρωμένη αξιολόγηση της αποτελεσματικότητας των σύγχρονων μεθόδων πρόβλεψης χρονοσειρών στην αγορά Forex. Η παρουσίαση των αποτελεσμάτων υποστηρίζεται από αναφορές σε σχετικές μελέτες.

Το κυρίως κείμενο περιλαμβάνει τις παρακάτω ενότητες:

- ΕΙΣΑΓΩΓΗ
- ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ ΚΑΙ ΑΝΑΣΚΟΠΗΣΗ ΒΙΒΛΙΟΓΡΑΦΙΑΣ
- ΔΕΔΟΜΕΝΑ ΚΑΙ ΕΞΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ (EDA)
- ΜΕΘΟΔΟΛΟΓΙΑ
- ΑΠΟΤΕΛΕΣΜΑΤΑ
- ΣΥΖΗΤΗΣΗ
- ΣΥΜΠΕΡΑΣΜΑΤΑ

1 ΕΙΣΑΓΩΓΗ

1.1 ΚΙΝΗΤΡΟ

Με την πρόοδο της τεχνολογίας και την αλματώδη αύξηση του όγκου των δεδομένων, η ανάλυση και η πρόβλεψη βασικών τάσεων αποκτούν ολοένα και μεγαλύτερη σημασία. Οι συναλλαγματικές ισοτιμίες, ως κρίσιμοι δείκτες οικονομικής σταθερότητας, διαδραματίζουν ιδιαίτερα σημαντικό ρόλο. Οι διακυμάνσεις στην αγορά συναλλάγματος (Forex) μπορούν να επηρεάσουν ουσιαστικά το διεθνές εμπόριο, τις ροές επενδύσεων και τις πολιτικές των κεντρικών τραπεζών. Στο σημερινό παγκοσμιοποιημένο περιβάλλον, ακόμη και μικρές μεταβολές στις συναλλαγματικές ισοτιμίες μπορεί να επιφέρουν σημαντικές συνέπειες για κράτη, επιχειρήσεις και ιδιώτες. Η παρούσα μελέτη αποσκοπεί στην αποσαφήνιση αυτών των δυναμικών μέσα από μια αυστηρή και ακριβή ανάλυση.

Η πρόβλεψη των τάσεων των συναλλαγματικών ισοτιμιών παραμένει σημαντική πρόκληση στο πεδίο της επιστήμης δεδομένων. Οι παραδοσιακές στατιστικές μέθοδοι συχνά αδυνατούν να αποτυπώσουν τα πολύπλοκα, μη γραμμικά πρότυπα που χαρακτηρίζουν την αγορά Forex. Οι πρόσφατες εξελίξεις στην τεχνητή νοημοσύνη και στη βαθιά μάθηση, ιδίως τα δίκτυα Long Short-Term Memory (LSTM), έχουν ενισχύσει τη δυνατότητα αναγνώρισης και μοντελοποίησης αυτών των προτύπων. Ωστόσο, τα μοντέλα LSTM συνήθως απαιτούν επανεκπαίδευση για κάθε νέο σύνολο δεδομένων, γεγονός που περιορίζει την προσαρμοστικότητά τους. Παρά τις προόδους αυτές, οι άμεσες συγκρίσεις μεταξύ foundation models και συμβατικών μοντέλων βαθιάς μάθησης στον χώρο του Forex παραμένουν ελάχιστες, ιδίως λόγω της υψηλής μεταβλητότητας και των ακανόνιστων διακυμάνσεων της αγοράς. Το κενό αυτό αναδεικνύει την ανάγκη για αυστηρές μελέτες που αξιολογούν την απόδοση των σύγχρονων μοντέλων σε απαιτητικές χρηματοοικονομικές συνθήκες. Παρέχοντας σαφείς επεξηγήσεις τεχνικών εννοιών, η παρούσα εργασία στοχεύει να διευκολύνει την κατανόηση προχωρημένων μεθόδων πρόβλεψης.

Τα foundation models, όπως το Lag-Llama, έχουν πρόσφατα μεταμορφώσει τις μεθοδολογίες πρόβλεψης. Τα μοντέλα αυτά εκπαιδεύονται εκ των προτέρων σε εκτενή σύνολα δεδομένων και μπορούν να προσαρμοστούν αποτελεσματικά σε μια σειρά από εργασίες πρόβλεψης με ελάχιστη πρόσθετη εκπαίδευση. Η σύγκριση ενός foundation model όπως το Lag-Llama με ένα παραδοσιακό μοντέλο βαθιάς μάθησης, όπως το LSTM, προσφέρει χρήσιμες πληροφορίες

σχετικά με το πώς οι πρόσφατες εξελίξεις στη μηχανική μάθηση μπορούν να ενισχύσουν την ακρίβεια και την προσαρμοστικότητα των μοντέλων πρόβλεψης στην αγορά Forex. Η συζήτηση που αναπτύσσεται στην παρούσα εργασία επιδιώκει να διατηρήσει επιστημονική αυστηρότητα, παραμένοντας ταυτόχρονα προσιτή σε αναγνώστες με περιορισμένο τεχνικό υπόβαθρο. Η διερεύνηση πιο αποδοτικών τεχνικών πρόβλεψης είναι ιδιαίτερα σχετική σε περιόδους αυξημένης αβεβαιότητας, όταν οι ιστορικές σχέσεις μεταξύ νομισματικών ζευγών ενδέχεται να μεταβάλλονται. Συνεπώς, η αξιολόγηση μοντέλων που μπορούν να προσαρμόζονται γρήγορα σε νέες συνθήκες έχει άμεσες εφαρμογές σε επενδυτικές στρατηγικές, αλγορίθμικό trading και μηχανισμούς διαχείρισης κινδύνου.

Το κίνητρο για την παρούσα έρευνα προκύπτει από την αυξανόμενη ανάγκη για μοντέλα πρόβλεψης που να είναι αξιόπιστα, ευέλικτα και αποδοτικά, ικανά να στηρίζουν τη λήψη τεκμηριωμένων αποφάσεων σε αγορές που εξελίσσονται ταχύτατα. Μέσω της ενσωμάτωσης σαφών επεξηγήσεων και αυστηρής ακαδημαϊκής ανάλυσης, η εργασία στοχεύει να καταστήσει τις σύγχρονες μεθόδους πρόβλεψης προσιτές και χρήσιμες σε ευρύ κοινό. Ως εκ τούτου, απαιτείται μια καλά δομημένη και εμπειρικά τεκμηριωμένη μελέτη για την ολοκληρωμένη σύγκριση των δύο προσεγγίσεων και την ανάπτυξη του πλαισίου των ερευνητικών στόχων και ερωτημάτων που πραγματεύεται η εργασία.

1.2 ΣΚΟΠΟΣ

Η παρούσα διπλωματική εργασία στοχεύει στη διεξοδική σύγκριση δύο διαφορετικών προσεγγίσεων για την πρόβλεψη συναλλαγματικών ισοτιμιών: του καθιερωμένου μοντέλου βαθιάς μάθησης Long Short-Term Memory (LSTM) και του νεότερου foundation model Lag-Llama. Μέσα από τη χρήση ημερήσιων δεδομένων χρονοσειρών, η έρευνα εξετάζει πώς αποδίδει κάθε μέθοδος σε ρεαλιστικά χρηματοοικονομικά σενάρια. Ο στόχος δεν είναι μόνο η αξιολόγηση της ακρίβειας και της αξιοπιστίας των προβλέψεων, αλλά και η κατανόηση του ποια προσέγγιση είναι πιο προσαρμόσιμη στις προκλήσεις του πραγματικού κόσμου. Η σύγκριση αυτή αποκτά ιδιαίτερη σημασία, καθώς τα δύο μοντέλα αντιπροσωπεύουν διαφορετικές φιλοσοφίες πρόβλεψης: το LSTM βασίζεται σε στοχευμένη εκπαίδευση ανά dataset, ενώ το Lag-Llama αξιοποιεί προϋπάρχουσα γενικευμένη γνώση. Έτσι, η εργασία επιχειρεί να διερευνήσει εάν τα foundation models μπορούν να προσφέρουν πρακτικό πλεονέκτημα σε πραγματικές χρηματοοικονομικές συνθήκες. Η ανάλυση δομείται με τρόπο που επιτρέπει την καθαρή αποτύπωση των ευρημάτων, χωρίς να χάνεται η απαιτούμενη επιστημονική αυστηρότητα.

Ειδικότερα, οι στόχοι της έρευνας είναι οι εξής:

- Να αξιολογηθεί η ικανότητα του μοντέλου LSTM να προβλέπει συναλλαγματικές ισοτιμίες για διαφορετικά ζεύγη νομισμάτων, με τη χρήση ευρέως αποδεκτών μετρικών πρόβλεψης. Η ανάλυση αυτή συμβάλλει στη διαμόρφωση μιας ολοκληρωμένης και αντικειμενικής εικόνας των πλεονεκτημάτων και αδυναμιών του μοντέλου σε διάφορα χρηματοοικονομικά περιβάλλοντα.
- Να διερευνηθεί η αποτελεσματικότητα του foundation model Lag-Llama, και ειδικότερα κατά πόσο μπορεί να προσφέρει αξιόπιστες προβλέψεις χωρίς να απαιτείται εκτεταμένη επανεκπαίδευση — χαρακτηριστικό που θα μπορούσε να το καθιστά ιδιαίτερα χρήσιμο σε πραγματικές εφαρμογές όπου τα δεδομένα ανανεώνονται διαρκώς.
- Να αναλυθεί ο βαθμός προσαρμοστικότητας κάθε μοντέλου σε διαφορετικά νομισματικά ζεύγη και χρονικές περιόδους, εστιάζοντας στη συνέπεια και αξιοπιστία της απόδοσής τους, ακόμη και όταν οι οικονομικές συνθήκες μεταβάλλονται. Ο στόχος αυτός είναι καθοριστικός για να διαπιστωθεί κατά πόσο τα μοντέλα μπορούν να αξιοποιηθούν πέρα από τα δεδομένα στα οποία αρχικά εκπαιδεύτηκαν.

- Να εντοπιστούν τα πλεονεκτήματα και οι περιορισμοί κάθε προσέγγισης, με ιδιαίτερη έμφαση στη δυνατότητα μεταφοράς γνώσης (knowledge transfer) σε άλλα προβλήματα πρόβλεψης. Η έρευνα εξετάζει, επίσης, πώς οι υπό μελέτη μέθοδοι μπορούν να εφαρμοστούν σε άλλους τομείς που βασίζονται σε δεδομένα χρονοσειρών, καθιστώντας τα αποτελέσματα της εργασίας χρήσιμα για ένα ευρύτερο κοινό.\

Μέσα από τους παραπάνω στόχους, η εργασία επιδιώκει να καλύψει ένα κενό στη σύγχρονη βιβλιογραφία, καθώς η άμεση εμπειρική σύγκριση foundation models με κλασικές αρχιτεκτονικές LSTM σε δεδομένα Forex παραμένει περιορισμένη. Η συμβολή της μελέτης εντοπίζεται τόσο στη μεθοδολογική σύγκριση όσο και στην αξιολόγηση της πρακτικής χρησιμότητας των μοντέλων σε διαφορετικές συνθήκες αγοράς.

1.3 ΕΠΕΥΝΗΤΙΚΑ ΕΡΩΤΗΜΑΤΑ

Τα παρακάτω ερευνητικά ερωτήματα διαμορφώνονται με στόχο τη συστηματική αξιολόγηση και σύγκριση των δύο μοντέλων πρόβλεψης:

- 1. Πόσο αποτελεσματικά προβλέπει το μοντέλο LSTM τις ημερήσιες συναλλαγματικές ισοτιμίες και πόσο συνεπής είναι η απόδοσή του σε διαφορετικά ζεύγη νομισμάτων;**

Σκοπός είναι η ανάδειξη των δυνατοτήτων και των περιορισμών του μοντέλου σε ποικίλα χρηματοοικονομικά περιβάλλοντα.

- 2. Σε ποιο βαθμό το foundation model Lag-Llama μπορεί να επιτύχει απόδοση συγκρίσιμη ή ανώτερη από το LSTM, ακόμη και χωρίς εκπαίδευση από την αρχή;**
Το ερώτημα εξετάζει κατά πόσο τα σύγχρονα foundation models προσφέρουν ουσιαστικά πλεονεκτήματα στην πρόβλεψη χρονοσειρών.
- 3. Πόσο σταθερά και ανθεκτικά είναι τα αποτελέσματα και των δύο μοντέλων όταν αξιολογούνται σε διαφορετικές χρονικές περιόδους και ζεύγη νομισμάτων;**

Η διερεύνηση αυτή είναι κρίσιμη για την αποτίμηση της προσαρμοστικότητάς τους σε πραγματικές συνθήκες αγοράς.

4. Ποια είναι τα κύρια πλεονεκτήματα και οι αδυναμίες κάθε προσέγγισης, και σε ποιο βαθμό μπορούν τα ευρήματα να γενικευθούν σε άλλους τύπους χρονοσειρών ή χρηματοοικονομικών δεδομένων;

Στόχος είναι η ανάδειξη της δυνητικής εφαρμοσιμότητας των μοντέλων σε τομείς πέραν της αγοράς συναλλάγματος.

2 ΘΕΩΡΗΤΙΚΟ ΥΠΟΒΑΘΡΟ ΚΑΙ ΑΝΑΣΚΟΠΗΣΗ ΒΙΒΛΙΟΓΡΑΦΙΑΣ

Το παρόν κεφάλαιο θέτει το πλαίσιο της έρευνας, παρουσιάζοντας τις βασικές έννοιες και προσεγγίσεις που αποτελούν το υπόβαθρο της πρόβλεψης χρηματοοικονομικών χρονοσειρών. Ξεκινά με την ανάλυση των χαρακτηριστικών που καθιστούν τα χρηματοοικονομικά δεδομένα μοναδικά και απαιτητικά, και στη συνέχεια εξετάζει τις πιο ευρέως χρησιμοποιούμενες στατιστικές μεθόδους πρόβλεψης στον συγκεκριμένο τομέα. Η συζήτηση επεκτείνεται στα σύγχρονα μοντέλα βαθιάς μάθησης, αναδεικνύοντας τη συνεισφορά των δικτύων Long Short-Term Memory (LSTM) στην εξέλιξη του πεδίου, ενώ στη συνέχεια εισάγει τα foundation models, όπως το Lag-Llama, τα οποία αντιπροσωπεύουν τις πιο πρόσφατες εξελίξεις. Το κεφάλαιο ολοκληρώνεται με μια συγκριτική ανασκόπηση πρόσφατων ερευνών, με σκοπό τον εντοπισμό των σημείων όπου η υπάρχουσα βιβλιογραφία παρουσιάζει ελλείψεις, διευκρινίζοντας έτσι τα ερευνητικά ερωτήματα και τα κενά που επιχειρεί να καλύψει η παρούσα εργασία. Σε όλο το κεφάλαιο, ο στόχος είναι να παρουσιαστούν οι έννοιες με σαφή και κατανοητό τρόπο, διατηρώντας παράλληλα την επιστημονική αυστηρότητα που απαιτείται.

2.1 ΙΔΙΑΙΤΕΡΟΤΗΤΕΣ ΧΡΗΜΑΤΟΟΙΚΟΝΟΜΙΚΩΝ ΧΡΟΝΟΣΕΙΡΩΝ

Οι χρηματοοικονομικές χρονοσειρές αποτελούνται από αριθμητικά δεδομένα που συλλέγονται διαχρονικά, όπως οι ημερήσιες τιμές μετοχών, τα επιτόκια διατραπεζικού δανεισμού ή οι συναλλαγματικές ισοτιμίες (Forex) που αποτυπώνουν τη σχέση μεταξύ δύο νομισμάτων. Σε αντίθεση με τις χρονοσειρές που συναντώνται στις φυσικές επιστήμες ή στη βιομηχανία, τα χρηματοοικονομικά δεδομένα είναι πολύ πιο απρόβλεπτα. Συχνά μεταβάλλονται με τρόπους δύσκολους να μοντελοποιηθούν, μπορούν να αλλάξουν κατεύθυνση απροσδόκητα και δεν ακολουθούν πάντοτε απλά ή γραμμικά πρότυπα. Οι ιδιαιτερότητες αυτές καθιστούν τα χρηματοοικονομικά δεδομένα ένα πεδίο όπου οι κλασικές παραδοχές στατιστικής μοντελοποίησης συχνά δεν ισχύουν, γεγονός που έχει αναδείξει την ανάγκη για πιο ευέλικτες και μη γραμμικές μεθόδους ανάλυσης. Παράγοντες όπως οι γεωπολιτικές εξελίξεις ή οι οικονομικές ειδήσεις επηρεάζουν έντονα τις τιμές, καθιστώντας τις χρονοσειρές αυτές ιδιαίτερα απαιτητικές για ερευνητές και επαγγελματίες του χώρου (Tsay, 2010).

Η ακριβής πρόβλεψη της μελλοντικής πορείας αυτών των δεδομένων έχει ζωτική σημασία όχι μόνο για ερευνητικούς σκοπούς, αλλά και για πρακτικές εφαρμογές όπως ο

αλγορίθμικός χρηματισμός, η διαχείριση επενδυτικού κινδύνου, οι στρατηγικές αντιστάθμισης (hedging) και η υποστήριξη ταχύτερης λήψης αποφάσεων από χρηματοπιστωτικούς οργανισμούς. Από ερευνητική σκοπιά, οι χρηματοοικονομικές χρονοσειρές αποτελούν ιδιαίτερα απαιτητικό αντικείμενο, καθώς σπάνια πληρούν τις αυστηρές μαθηματικές προϋποθέσεις (όπως τη γραμμικότητα ή την κανονικότητα) πάνω στις οποίες βασίζονται τα κλασικά στατιστικά μοντέλα πρόβλεψης.

Επιπρόσθετα, η Θεωρία των Αποτελεσματικών Αγορών (Efficient Market Hypothesis – EMH) υποστηρίζει ότι οι τιμές ενσωματώνουν ήδη κάθε διαθέσιμη πληροφορία, γεγονός που σημαίνει ότι, θεωρητικά, η αξιόπιστη πρόβλεψή τους είναι αδύνατη (Fama, 1970). Παρ' όλα αυτά, οι πρόσφατες εξελίξεις στη βαθιά μάθηση και ειδικότερα η ανάπτυξη προχωρημένων μοντέλων σχεδιασμένων για χρονοσειρές έχουν αναζωπυρώσει το ερευνητικό ενδιαφέρον σχετικά με το εάν είναι δυνατό να εντοπιστούν χρήσιμα μοτίβα ακόμη και σε αγορές που θεωρούνται χαοτικές και μη προβλέψιμες. Αυτό το παράδοξο, η θεωρητική απουσία προβλεψιμότητας έναντι της πρακτικής αναζήτησης μοτίβων, έχει αποτελέσει κεντρικό σημείο ενδιαφέροντος στη σχετική βιβλιογραφία, οδηγώντας σε πλήθος προσεγγίσεων που επιχειρούν να εντοπίσουν έστω και μικρής έντασης συστηματικές δομές μέσα στο θόρυβο των αγορών.

Συνοψίζοντας, η πρόβλεψη χρηματοοικονομικών χρονοσειρών είναι εξαιρετικά απαιτητική λόγω της πολύπλοκης συμπεριφοράς και της υψηλής μεταβλητότητάς τους. Στην επόμενη ενότητα παρουσιάζονται οι βασικές κλασικές μέθοδοι πρόβλεψης, οι οποίες αποτέλεσαν τη θεωρητική βάση για την ανάπτυξη των σύγχρονων μοντέλων βαθιάς μάθησης και των foundation models, προετοιμάζοντας το έδαφος για την κατανόηση τόσο της προόδου όσο και των συνεχιζόμενων προκλήσεων στον τομέα αυτό. Η κατανόηση αυτών των ιδιαιτεροτήτων αποτελεί κρίσιμο υπόβαθρο για την αξιολόγηση των σύγχρονων τεχνικών πρόβλεψης που εξετάζονται στις επόμενες ενότητες.

2.2 ΚΛΑΣΙΚΕΣ ΠΡΟΣΕΓΓΙΣΕΙΣ ΠΡΟΒΛΕΨΗΣ ΧΡΟΝΟΣΕΙΡΩΝ ΚΑΙ ΠΕΡΙΟΡΙΣΜΟΙ

Παραδοσιακά, η πρόβλεψη χρονοσειρών βασίστηκε σε γνωστά στατιστικά μοντέλα, όπως τα ARIMA (Autoregressive Integrated Moving Average) και SARIMA. Οι προσεγγίσεις αυτές προβλέπουν μελλοντικές τιμές αξιοποιώντας προηγούμενες παρατηρήσεις και σφάλματα πρόβλεψης, επιτυγχάνοντας τα καλύτερα αποτελέσματα όταν τα δεδομένα παρουσιάζουν σταθερότητα και ομαλές μεταβολές με την πάροδο του χρόνου. Στην πράξη, τα μοντέλα αυτά είναι πιο αποτελεσματικά όταν η χρονοσειρά δεν υπόκειται σε ξαφνικές απρόβλεπτες διακυμάνσεις, γεγονός που τα καθιστά λιγότερο κατάλληλα για περιβάλλοντα υψηλής μεταβλητότητας, όπως οι χρηματοοικονομικές αγορές.

Ωστόσο, όταν εφαρμόζονται σε χρηματοοικονομικές χρονοσειρές και ιδιαίτερα στις συναλλαγματικές ισοτιμίες (FOREX) τα κλασικά αυτά μοντέλα παρουσιάζουν σημαντικούς περιορισμούς για διάφορους λόγους:

- Δυσκολεύονται να αποτυπώσουν τις πολύπλοκες, μη γραμμικές και ταχέως μεταβαλλόμενες σχέσεις που χαρακτηρίζουν τα χρηματοοικονομικά δεδομένα.
- Βασίζονται στην υπόθεση της στασιμότητας δηλαδή ενός σταθερού, αμετάβλητου υποκείμενου μηχανισμού η οποία σπάνια ισχύει στις πραγματικές αγορές. Επιπλέον, τα κλασικά μοντέλα συχνά αγνοούν σημαντικούς εξωγενείς παράγοντες, όπως οι μεταβολές επιτοκίων, οι παρεμβάσεις των κεντρικών τραπεζών ή οι γεωπολιτικές εξελίξεις, παρότι αυτοί έχουν καθοριστική επίδραση στη συμπεριφορά των αγορών.
- Επίσης, οι μέθοδοι αυτές δεν έχουν σχεδιαστεί ώστε να αναγνωρίζουν ή να μαθαίνουν μακροπρόθεσμα μοτίβα στα δεδομένα, με αποτέλεσμα να εστιάζουν κυρίως σε βραχυπρόθεσμες κινήσεις και όχι σε ευρύτερες τάσεις.

Η Θεωρία των Αποτελεσματικών Αγορών (Efficient Market Hypothesis – EMH) (Fama, 1970) περιπλέκει περαιτέρω το πλαίσιο, καθώς υποστηρίζει ότι οι τιμές των περιουσιακών στοιχείων ενσωματώνουν άμεσα κάθε διαθέσιμη πληροφορία, γεγονός που υποδηλώνει ότι η παραδοσιακή πρόβλεψη δεν θα έπρεπε να λειτουργεί. Παρ' όλα αυτά, πολλές ερευνητικές μελέτες έχουν δείξει ότι ορισμένα μοτίβα και βαθμοί προβλεψιμότητας εξακολουθούν να υπάρχουν ιδίως όταν χρησιμοποιούνται πιο προχωρημένες, μη γραμμικές τεχνικές μηχανικής μάθησης.

Επειδή τα συμβατικά στατιστικά μοντέλα συχνά αποτυγχάνουν σε περιβάλλοντα υψηλής πολυπλοκότητας και μεταβλητότητας, όπως η αγορά FOREX, οι ερευνητές στράφηκαν σταδιακά σε νευρωνικά δίκτυα. Ιδιαίτερα, τα Long Short-Term Memory (LSTM) δίκτυα και πιο πρόσφατα τα foundation models, όπως το Lag-Llama αναπτύχθηκαν με στόχο να αντιμετωπίσουν τους περιορισμούς των κλασικών μεθόδων, προσφέροντας νέες δυνατότητες για πιο ακριβή και προσαρμόσιμη πρόβλεψη στις χρηματοοικονομικές αγορές.

2.3 ΝΕΥΡΩΝΙΚΑ ΔΙΚΤΥΑ ΓΙΑ ΠΡΟΒΛΕΨΗ ΧΡΟΝΟΣΕΙΡΩΝ – ΜΟΝΤΕΛΟ LSTM

Η υιοθέτηση των νευρωνικών δικτύων στην ανάλυση χρονοσειρών αποτέλεσε ένα καθοριστικό σημείο καμπής, καθώς μετέφερε το πεδίο πέρα από τους περιορισμούς των γραμμικών στατιστικών μοντέλων προς πιο ευέλικτες και ισχυρές μη γραμμικές μεθόδους μάθησης. Τα Επαναλαμβανόμενα Νευρωνικά Δίκτυα (Recurrent Neural Networks – RNNs) διαδραμάτισαν καίριο ρόλο σε αυτή τη μετάβαση, καθώς επέτρεψαν στους ερευνητές να μοντελοποιήσουν τον τρόπο με τον οποίο τα πρότυπα και οι συσχετίσεις εξελίσσονται διαχρονικά μέσα σε μια ακολουθία δεδομένων ένα κρίσιμο βήμα για τη διατύπωση τεκμηριωμένων προβλέψεων σε πραγματικές εφαρμογές.

Παρά την αξία τους, τα κλασικά RNNs παρουσιάζουν σημαντικές προκλήσεις, όπως το πρόβλημα vanishing ή exploding gradient, το οποίο καθιστά δύσκολη τη διατήρηση πληροφοριών για μεγάλα χρονικά διαστήματα. Για την αντιμετώπιση του ζητήματος αυτού, οι Hochreiter και Schmidhuber (1997) πρότειναν το Long Short-Term Memory (LSTM) δίκτυο. Το στοιχείο που διαφοροποιεί τα LSTM από τα παραδοσιακά RNNs είναι η χρήση πυλών (gates) ειδικών μηχανισμών που επιτρέπουν στο μοντέλο να αποφασίζει, σε κάθε χρονικό βήμα, ποιες πληροφορίες είναι αρκετά σημαντικές ώστε να διατηρηθούν και ποιες μπορούν να απορριφθούν με ασφάλεια. Αυτή η καινοτομία επιτρέπει στα LSTM να συλλαμβάνουν μακροπρόθεσμα πρότυπα και εξαρτήσεις, τις οποίες τα απλούστερα μοντέλα αδυνατούν να αναγνωρίσουν.

Σε αρχιτεκτονικό επίπεδο, ένα LSTM αποτελείται από τρεις κύριες πύλες:

- Forget Gate: καθορίζει ποιες πληροφορίες από προηγούμενα χρονικά βήματα δεν είναι πλέον σχετικές και πρέπει να αφαιρεθούν από την εσωτερική κατάσταση του κυττάρου.

- Input Gate: ρυθμίζει ποιες νέες πληροφορίες θα ενσωματωθούν στην εσωτερική μνήμη.
- Output Gate: προσδιορίζει ποιο τμήμα της κατάστασης του κυττάρου θα χρησιμοποιηθεί για την παραγωγή της εξόδου σε κάθε χρονικό βήμα.

Ο συνδυασμός αυτών των πυλών επιτρέπει στο LSTM να ελέγχει τη ροή της πληροφορίας με τρόπο που μειώνει τα προβλήματα διάχυσης του σφάλματος (vanishing gradient), καθιστώντας τη δομή του κατάλληλη για πιο σύνθετες και ασταθείς χρονοσειρές όπως οι χρηματοοικονομικές.

Μέσω αυτών των μηχανισμών, τα LSTM έχουν τη δυνατότητα να διατηρούν και να αξιοποιούν πληροφορίες από προηγούμενα χρονικά βήματα, επιτρέποντας τη μοντελοποίηση μακροχρόνιων χρονικών εξαρτήσεων. Η ιδιότητα αυτή τα καθιστά ιδιαίτερα κατάλληλα για την πρόβλεψη συναλλαγματικών ισοτιμιών και άλλων χρηματοοικονομικών χρονοσειρών που χαρακτηρίζονται από περίπλοκη και δυναμική συμπεριφορά.

Παρά την αποτελεσματικότητά τους, τα LSTM παρουσιάζουν ορισμένους ερευνητικούς περιορισμούς:

- Τα μοντέλα LSTM συνήθως πρέπει να εκπαιδεύονται ανεξάρτητα για κάθε νέο σύνολο δεδομένων, καθώς δεν διαθέτουν μηχανισμούς αποτελεσματικής μεταφοράς γνώσης μεταξύ διαφορετικών προβλημάτων.
- Η προβλεπτική τους απόδοση και η αναπαραστατική τους ικανότητα εξαρτώνται σε μεγάλο βαθμό από τη διαθεσιμότητα μεγάλων συνόλων εκπαίδευσης. συνεπώς, είναι επιρρεπή σε υπερεκπαίδευση (overfitting) σε περιπτώσεις περιορισμένων δεδομένων.
- Η εκπαίδευσή τους είναι υπολογιστικά δαπανηρή, ιδιαίτερα όταν αυξάνεται το μήκος των ακολουθιών εισόδου και ο αριθμός των παραμέτρων του μοντέλου.

Παρά τους παραπάνω περιορισμούς, τα LSTM εξακολουθούν να αποτελούν πρότυπο μοντέλο αναφοράς (baseline) στη διεθνή βιβλιογραφία για την πρόβλεψη χρονοσειρών. Κατά συνέπεια, η παρούσα εργασία αξιοποιεί το LSTM ως σημείο σύγκρισης, προκειμένου να αξιολογηθεί εάν ένα σύγχρονο foundation model, όπως το Lag-Llama, μπορεί να υπερβεί την προβλεπτική του απόδοση και να επιδείξει μεγαλύτερη προσαρμοστικότητα σε πραγματικά χρηματοοικονομικά δεδομένα.

2.4 FOUNDATION MODELS KAI ARXITEKTONIKH TRANSFORMER ΓΙΑ ΧΡΟΝΟΣΕΙΡΕΣ

Τα τελευταία χρόνια, έχει παρατηρηθεί αυξανόμενο ενδιαφέρον από την ερευνητική κοινότητα γύρω από τα foundation models μεγάλα, προ εκπαιδευμένα μοντέλα που βασίζονται σε εκτενή και ετερογενή σύνολα δεδομένων. Τα μοντέλα αυτά ξεχωρίζουν διότι, μετά την αρχική τους εκπαίδευση, μπορούν να προσαρμοστούν (fine-tuned) σε συγκεκριμένες εργασίες με ελάχιστο επιπλέον υπολογιστικό κόστος (Bommasani et al., 2021). Σε αντίθεση με τα παραδοσιακά μοντέλα, όπως τα LSTM, τα οποία μαθαίνουν κάθε φορά από ένα και μόνο σύνολο δεδομένων, τα foundation models έχουν σχεδιαστεί ώστε να συσσωρεύουν γενικευμένη γνώση που μπορεί να αξιοποιηθεί σε διαφορετικά πεδία εφαρμογής. Αυτή η ιδιότητα τα καθιστά ιδιαίτερα υποσχόμενα για περιπτώσεις όπου τα δεδομένα παρουσιάζουν μεγάλη ποικιλομορφία, όπως συμβαίνει συνήθως στην πρόβλεψη χρηματοοικονομικών χρονοσειρών.

Στην καρδιά αυτής της μετάβασης βρίσκεται η αρχιτεκτονική Transformer (Vaswani et al., 2017), η οποία βασίζεται σε έναν μηχανισμό που ονομάζεται αυτοπροσοχή (self-attention). Σε αντίθεση με τα LSTM, τα οποία επεξεργάζονται τις πληροφορίες διαδοχικά, οι Transformers είναι σε θέση να εξετάζουν όλα τα χρονικά βήματα ταυτόχρονα, επιτρέποντας στο μοντέλο να αντιλαμβάνεται πώς σχετίζονται μεταξύ τους οποιαδήποτε δύο σημεία μιας ακολουθίας, ανεξάρτητα από τη χρονική τους απόσταση. Αυτή η παράλληλη επεξεργασία αποτελεί μια καθοριστική καινοτομία που έχει αλλάξει ριζικά τον τρόπο με τον οποίο οι ερευνητές προσεγγίζουν προβλήματα που περιλαμβάνουν πολύπλοκα διαδοχικά δεδομένα.

Χάρη σε αυτή τη δυνατότητα, οι Transformers μπορούν να συλλαμβάνουν μακροπρόθεσμα πρότυπα και εξαρτήσεις στα δεδομένα, χωρίς να υποφέρουν από τη σταδιακή απώλεια πληροφορίας που περιορίζει πολλά επαναληπτικά δίκτυα. Στο πεδίο της πρόβλεψης χρονοσειρών, αυτή η ικανότητα επιτρέπει στα μοντέλα να εντοπίζουν πολύπλοκες και μακροχρόνιες συσχετίσεις, οι οποίες εξελίσσονται σε βάθος χρόνου ένα κρίσιμο πλεονέκτημα όταν πρόκειται για την ανάλυση απρόβλεπτων χρηματοοικονομικών δεδομένων.

Πρόσφατες μελέτες έχουν δείξει ότι οι Transformers μπορούν να γενικεύουν καλύτερα σε σχέση με τα κλασικά μοντέλα που βασίζονται σε RNN, ιδίως όταν πρόκειται για πολυμεταβλητές, μη στατικές και ακόμη και χαοτικές χρονοσειρές, όπως αυτές που συναντώνται στις χρηματοοικονομικές αγορές (Zerveas et al., 2021). Επειδή έχουν προ εκπαιδευτεί σε ένα ευρύ φάσμα διαφορετικών τύπων χρονοσειρών όπως χρηματοοικονομικά,

δεδομένα IoT, κλιματικά ή αισθητήρων τα foundation models αποκτούν υψηλό βαθμό ευελιξίας και προσαρμοστικότητας. Αυτή η ιδιότητα τα καθιστά ιδανικά για πρόβλεψη στην αγορά συναλλάγματος (FOREX), όπου οι τύποι και η ποιότητα των διαθέσιμων δεδομένων μπορεί να διαφέρουν σημαντικά από ζεύγος νομισμάτων σε ζεύγος.

Η μετάβαση από την ανάπτυξη ξεχωριστών μοντέλων για κάθε εργασία πρόβλεψης προς τη δημιουργία καθολικών μοντέλων χρονοσειρών αποτελεί μία από τις σημαντικότερες πρόσφατες εξελίξεις στην έρευνα των χρονοσειρών. Στο πλαίσιο αυτής της νέας προσέγγισης, το Lag-Llama ξεχωρίζει, καθώς εισάγει μια καινοτόμο φιλοσοφία: αντί να ξεκινά κάθε φορά η εκπαίδευση ενός νέου μοντέλου από την αρχή, αξιοποιείται ένα foundation model που διαθέτει ήδη βαθιά κατανόηση της δομής των χρονοσειρών. Το μοντέλο αυτό μπορεί στη συνέχεια να καθοδηγηθεί μέσω prompting ή με μικρή επιπλέον εκπαίδευση για να επιλύσει νέες εργασίες πρόβλεψης γρήγορα και αποδοτικά, εξοικονομώντας χρόνο και υπολογιστικούς πόρους.

2.5 ΤΟ MONTELO LAG – LLAMA: FOUNDATION MODEL ΕΞΕΙΔΙΚΕΤΜΕΝΟ ΓΙΑ ΧΡΟΝΟΣΕΙΡΕΣ

Το Lag-Llama αποτελεί ένα από τα πρώτα foundation models που έχουν σχεδιαστεί αποκλειστικά για την πρόβλεψη χρονοσειρών, αξιοποιώντας αρχιτεκτονική τύπου Transformer η οποία είναι ειδικά προσαρμοσμένη στις ιδιαιτερότητες των αριθμητικών δεδομένων (Oreshkin et al., 2023). Αυτό που διαφοροποιεί το Lag-Llama από τα παραδοσιακά μοντέλα βαθιάς μάθησης, όπως εκείνα που απαιτούν εκπαίδευση από την αρχή πάνω σε ένα μόνο dataset, είναι η έκθεσή του σε ένα τεράστιο και ετερογενές σύνολο χρονοσειρών κατά τη φάση της προ εκπαίδευσης. Τα δεδομένα αυτά προέρχονται από πολλαπλές πηγές, όπως χρηματοοικονομικά δεδομένα, αισθητήρες IoT, βιομηχανικές διεργασίες και ενεργειακά συστήματα. Μέσω αυτής της εκτεταμένης εκπαίδευσης, το Lag-Llama αποκτά τη δυνατότητα να αναγνωρίζει γενικά πρότυπα χρονικής εξέλιξης των δεδομένων. Έτσι, μπορεί να προσαρμόζεται σε νέα σύνολα δεδομένων με ελάχιστη επιπλέον εκπαίδευση, ενώ σε ορισμένες περιπτώσεις μπορεί να πραγματοποιεί ακριβείς προβλέψεις “out of the box”, χωρίς να απαιτείται εκτεταμένη διαδικασία επανεκπαίδευσης όπως συμβαίνει στα συμβατικά μοντέλα. Σε αντίθεση με τα κλασικά μεγάλα γλωσσικά μοντέλα που εκπαιδεύονται κυρίως σε κείμενο, το Lag-Llama έχει σχεδιαστεί εξαρχής με γνώμονα τα αριθμητικά δεδομένα, ενσωματώνοντας κατάλληλους μηχανισμούς ώστε να συλλαμβάνει χρονικά μοτίβα και όχι γλωσσικές δομές.

Μία από τις κύριες προκλήσεις στην προσαρμογή των Transformer αρχιτεκτονικών σε δεδομένα χρονοσειρών είναι ότι τα μοντέλα αυτά αρχικά σχεδιάστηκαν για φυσική γλώσσα, όπου η πληροφορία οργανώνεται σε διακριτές μονάδες, τις λέξεις ή tokens. Αντίθετα, οι χρονοσειρές αποτελούνται από συνεχείς ροές αριθμητικών τιμών, γεγονός που καθιστά δύσκολη την άμεση εφαρμογή των ίδιων τεχνικών. Για να αντιμετωπίσει αυτή τη δυσκολία, το Lag-Llama εφαρμόζει μια στρατηγική tokenization μέσω patching, η οποία λειτουργεί ως εξής:

- Η χρονοσειρά διαιρείται σε τμήματα (patches) σταθερού μήκους, για παράδειγμα παράθυρα 32 ή 64 τιμών.
- Κάθε patch κανονικοποιείται (normalized) ώστε να εξισορροπηθεί η κλίμακα των τιμών μεταξύ δειγμάτων.
- Οι κανονικοποιημένες τιμές ποσοτικοποιούνται (quantized) και μετατρέπονται σε διακριτά tokens.

- Τα tokens αυτά εισάγονται σε έναν Transformer encoder, επιτρέποντας στο μοντέλο να συλλάβει μακροχρόνιες χρονικές εξαρτήσεις, πέρα από τα τοπικά μοτίβα βραχυπρόθεσμης φύσης.

Η διαδικασία αυτή επιτρέπει στο μοντέλο να εξάγει αναπαραστάσεις που είναι ανθεκτικές σε θόρυβο και διακυμάνσεις, χαρακτηριστικό ιδιαίτερα κρίσιμο για χρηματοοικονομικά δεδομένα όπου η μεταβλητότητα είναι υψηλή και οι τάσεις δύσκολα εντοπίσιμες.

Με την παραπάνω διαδικασία, το Lag-Llama μπορεί να “διαβάζει” αριθμητικά δεδομένα με τρόπο παρόμοιο με αυτόν που ένα γλωσσικό μοντέλο “διαβάζει” λέξεις. Αυτή η καινοτομία μεταφέρει τη λογική των foundation models, που αρχικά αναπτύχθηκαν για την επεξεργασία φυσικής γλώσσας, στο πεδίο της πρόβλεψης χρονοσειρών, ανοίγοντας νέους δρόμους για την κατανόηση και την πρόβλεψη πολύπλοκων αριθμητικών δεδομένων.

Η πρόσφατη ερευνητική βιβλιογραφία αναδεικνύει ορισμένα βασικά πλεονεκτήματα του Lag-Llama σε σύγκριση με τα παραδοσιακά ή εξειδικευμένα μοντέλα. Πρώτον, παρουσιάζει αυξημένη γενικευσιμότητα (generalization ability), καθώς προσαρμόζεται αποτελεσματικά σε νέα datasets με ελάχιστη επιπλέον εκπαίδευση. Δεύτερον, διαθέτει τη δυνατότητα μεταφοράς γνώσης (knowledge transfer), αξιοποιώντας πρότυπα και μοτίβα που έχει μάθει από διαφορετικούς τύπους χρονοσειρών για να βελτιώσει την απόδοσή του σε άγνωστες εργασίες. Επιπλέον, υποστηρίζει την ταυτόχρονη πρόβλεψη πολλών ισοτιμιών Forex χωρίς την ανάγκη ξεχωριστής εκπαίδευσης για κάθε μία. Παράλληλα, επιδεικνύει υψηλή κλιμακωσιμότητα (scalability), εκμεταλλευόμενο τις δυνατότητες παράλληλης επεξεργασίας του μηχανισμού self-attention. Τέλος, υποστηρίζει λειτουργίες zero-shot και few-shot inference, διατηρώντας υψηλή προβλεπτική ικανότητα ακόμη και σε περιπτώσεις περιορισμένων δεδομένων, όπως σε περιόδους έντονης οικονομικής μεταβλητότητας.

Όλα τα παραπάνω καθιστούν το Lag-Llama ιδιαίτερα κατάλληλο για την πρόβλεψη συναλλαγματικών ισοτιμιών, όπου οι χρονοσειρές χαρακτηρίζονται από υψηλή αστάθεια, μη γραμμικότητα και περίπλοκες επιδράσεις εξωτερικών παραγόντων. Το Lag-Llama δεν αποτελεί απλώς ένα ακόμη νευρωνικό μοντέλο πρόβλεψης, αλλά αντιπροσωπεύει μια νέα ερευνητική προσέγγιση. Αντί να βασίζεται σε εξειδικευμένα, περιορισμένης εμβέλειας μοντέλα, προωθεί την ανάπτυξη καθολικών foundation models που μπορούν να λειτουργήσουν ως ευέλικτα και προσαρμόσιμα εργαλεία για ένα ευρύ φάσμα προβλημάτων πρόβλεψης. Στο πλαίσιο της παρούσας διπλωματικής εργασίας, το Lag-Llama προσφέρει μια ισχυρή υποδομή

για την πρόβλεψη συναλλαγματικών ισοτιμιών (Forex), αναδεικνύοντας πώς οι σύγχρονες τεχνικές μηχανικής μάθησης μπορούν να εφαρμοστούν αποτελεσματικά και πρακτικά σε πραγματικά χρηματοοικονομικά δεδομένα.

2.6 ΕΠΙΛΟΓΗ ΕΡΕΥΝΗΤΙΚΗΣ ΠΡΟΣΕΓΓΙΣΗΣ

Κατά τις δύο τελευταίες δεκαετίες, η έρευνα στον τομέα της πρόβλεψης χρηματοοικονομικών χρονοσειρών έχει υποστεί εντυπωσιακή εξέλιξη. Ο κλάδος έχει μετακινηθεί από τις παραδοσιακές στατιστικές προσεγγίσεις, όπως το μοντέλο ARIMA το οποίο προσέφερε ένα ισχυρό θεωρητικό υπόβαθρο για βραχυπρόθεσμες προβλέψεις σε σταθερά περιβάλλοντα, προς πιο προηγμένες τεχνικές βαθιάς μάθησης και, πιο πρόσφατα, στα foundation models. Αν και οι πρώτες αυτές μέθοδοι υπήρξαν ιδιαίτερα χρήσιμες, δυσκολεύονταν να αποτυπώσουν την πολύπλοκη, μη γραμμική και συχνά χαοτική συμπεριφορά που χαρακτηρίζει τις αγορές συναλλάγματος (Forex). Η μετάβαση αυτή αντικατοπτρίζει τη διαρκώς αυξανόμενη αναγνώριση ότι τα χρηματοοικονομικά δεδομένα σπάνια πληρούν τις αυστηρές υποθέσεις των κλασικών μοντέλων, γεγονός που απαιτεί πιο ευέλικτα και ισχυρά εργαλεία ανάλυσης. Παράλληλα, η αυξανόμενη διαθεσιμότητα μεγάλων δημόσιων datasets και η πρόοδος των υπολογιστικών υποδομών καθιστούν την παρούσα χρονική περίοδο ιδανική για εμπειρικές συγκρίσεις μεταξύ παραδοσιακών και προχωρημένων μοντέλων, επιτρέποντας πιο ρεαλιστική αξιολόγηση της πρακτικής τους αξίας.

Η εμφάνιση των Recurrent Neural Networks (RNNs) και, ειδικότερα, των Long Short-Term Memory (LSTM) δικτύων, αποτέλεσε σημείο καμπής στην προσέγγιση της ανάλυσης χρονοσειρών. Οι καινοτόμες αυτές αρχιτεκτονικές κατέστησαν δυνατή τη μοντελοποίηση μακροπρόθεσμων εξαρτήσεων, επιτρέποντας την κατανόηση του τρόπου με τον οποίο τα γεγονότα και οι τιμές σχετίζονται διαχρονικά, κάτι που δεν ήταν εφικτό με τα κλασικά στατιστικά μοντέλα. Πλήθος ερευνών έχει δείξει ότι τα LSTM συχνά υπερέχουν έναντι των παραδοσιακών προσεγγίσεων, ιδιαίτερα όταν τα δεδομένα παρουσιάζουν μη γραμμικές σχέσεις ή υψηλή μεταβλητότητα, όπως συμβαίνει συνήθως στις χρηματοοικονομικές αγορές. Ωστόσο, τα LSTM δεν είναι απαλλαγμένα από περιορισμούς, καθώς απαιτούν επανεκπαίδευση για κάθε νέο σύνολο δεδομένων, είναι υπολογιστικά απαιτητικά και επιρρεπή σε υπερεκπαίδευση. Αυτές οι προκλήσεις οδήγησαν την επιστημονική κοινότητα στην αναζήτηση πιο ευέλικτων και ανθεκτικών εναλλακτικών λύσεων.

Πρόσφατα, η ερευνητική προσοχή έχει στραφεί προς τα foundation models και τις αρχιτεκτονικές Transformer, οι οποίες έχουν αλλάξει ριζικά τον τρόπο με τον οποίο αναλύονται και κατανοούνται τα δεδομένα χρονοσειρών. Σημαντικές μελέτες, όπως αυτές

των Zerveas et al. (2021) και Oreshkin et al. (2023), έδειξαν ότι τα προ εκπαιδευμένα μοντέλα μπορούν να επιτύχουν επιδόσεις συγκρίσιμες ή και ανώτερες από τα LSTM σε διάφορους τομείς, συμπεριλαμβανομένων των χρηματοοικονομικών δεδομένων. Ιδιαίτερα σημαντικό είναι ότι τα μοντέλα αυτά μπορούν να προσαρμοστούν σε εξειδικευμένες εργασίες μέσω fine-tuning ή, σε ορισμένες περιπτώσεις, να εφαρμοστούν απευθείας χωρίς πρόσθετη εκπαίδευση, μέσω της διαδικασίας zero-shot inference. Η ευελιξία αυτή καθιστά τα foundation models ιδιαίτερα ελκυστικά σε περιβάλλοντα με περιορισμένα ή ασταθή δεδομένα, όπως συμβαίνει συχνά στην πραγματική χρηματοοικονομική πρόβλεψη.

Παρά την ταχεία αυτή πρόοδο, η υπάρχουσα βιβλιογραφία εξακολουθεί να παρουσιάζει σημαντικά κενά. Πρώτον, η έρευνα που συγκρίνει άμεσα τα foundation models με τις αρχιτεκτονικές LSTM σε δεδομένα συναλλαγματικών ισοτιμιών παραμένει περιορισμένη, παρότι οι ισοτιμίες αποτελούν ένα από τα πιο ασταθή και απρόβλεπτα είδη χρηματοοικονομικών σειρών. Δεύτερον, δεν υπάρχουν επαρκή εμπειρικά στοιχεία σχετικά με το κατά πόσο τα foundation models μπορούν να γενικεύσουν αποτελεσματικά σε διαφορετικά ζεύγη νομισμάτων και χρονικές περιόδους, ιδίως όταν οι μακροοικονομικές συνθήκες μεταβάλλονται. Τρίτον, απαιτείται περαιτέρω διερεύνηση για να διαπιστωθεί εάν τα foundation models μπορούν να διατηρούν σταθερή ακρίβεια πρόβλεψης χωρίς επανεκπαίδευση από την αρχή και ποια είναι τα πραγματικά τους πλεονεκτήματα ως προς την ακρίβεια και το υπολογιστικό κόστος.

Η παρούσα διπλωματική εργασία επιδιώκει να καλύψει αυτά τα ερευνητικά κενά μέσω μιας συστηματικής συγκριτικής ανάλυσης των μοντέλων LSTM και Lag-Llama, εφαρμόζοντάς τα σε πραγματικά δεδομένα ισοτιμιών Forex. Με αυτόν τον τρόπο, στοχεύει να αξιολογήσει τον βαθμό ακρίβειας, συνέπειας και αποδοτικότητας των δύο προσεγγίσεων και να διερευνήσει κατά πόσο τα foundation models μπορούν να αποτελέσουν μια πιο σύγχρονη και προσαρμόσιμη λύση για την πρόβλεψη σύνθετων χρηματοοικονομικών χρονοσειρών. Παράλληλα, η εργασία επιδιώκει να συνδυάσει την επιστημονική αυστηρότητα με τη σαφή παρουσίαση, ώστε τα αποτελέσματα να είναι κατανοητά και χρήσιμα τόσο για ερευνητές όσο και για επαγγελματίες που δραστηριοποιούνται στον χώρο της χρηματοοικονομικής πρόβλεψης. Ως αποτέλεσμα, η επιλογή αυτής της ερευνητικής ιδέας προέκυψε φυσικά μέσα από τα κενά της υπάρχουσας βιβλιογραφίας και τη σημασία του προβλήματος. Στο επόμενο κεφάλαιο παρουσιάζεται αναλυτικά η μεθοδολογική προσέγγιση που ακολουθήθηκε, ώστε να πραγματοποιηθεί η σύγκριση των δύο μοντέλων με τρόπο αξιόπιστο και επιστημονικά τεκμηριωμένο.

3 ΔΕΔΟΜΕΝΑ ΚΑΙ ΕΞΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ (EDA)

3.1 ΠΗΓΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΧΑΡΑΚΤΗΡΙΣΤΙΚΑ ΤΟΥ FOREX DATASET

Τα δεδομένα που χρησιμοποιήθηκαν στην παρούσα έρευνα προέρχονται από το δημόσια διαθέσιμο dataset “Daily Currency Exchange Rates (2008 – 2023)”, το οποίο είναι προσβάσιμο μέσω της πλατφόρμας Kaggle. Το συγκεκριμένο dataset παρέχει ιστορικές ημερήσιες συναλλαγματικές ισοτιμίες (Forex) για ένα ευρύ φάσμα νομισματικών ζευγών, χρησιμοποιώντας ως νόμισμα αναφοράς το ευρώ (EUR). Η επιλογή του έγινε τόσο για λόγους προσβασιμότητας όσο και λόγω της καταλληλότητάς του για ακαδημαϊκή και μεθοδολογικά αυστηρή ανάλυση.

Η επιλογή του dataset βασίστηκε στα ακόλουθα κριτήρια:

- Εκτεταμένη χρονική κάλυψη (2008–2023):** Η διάρκεια των δεδομένων επιτρέπει τη μελέτη μακροχρόνιων τάσεων και τη διερεύνηση της συμπεριφοράς των ισοτιμιών σε περιόδους οικονομικής κρίσης, ανάκαμψης και γεωπολιτικών αναταράξεων.
- Σταθερή ημερήσια συχνότητα:** Η συστηματική καταγραφή εξαλείφει ελλείψεις ή εποχικά κενά, ενισχύοντας την αξιοπιστία της ανάλυσης και περιορίζοντας την ανάγκη τεχνητής συμπλήρωσης.
- Ποικιλία συναλλαγματικών ζευγών:** Η ύπαρξη πολλών νομισματικών ζευγών επιτρέπει συγκρίσεις σε περιβάλλοντα με διαφορετική μεταβλητότητα, γεγονός απαραίτητο για την ολοκληρωμένη αξιολόγηση των υπό μελέτη μοντέλων.

Πριν την εφαρμογή των μοντέλων, πραγματοποιήθηκε βασική προεπεξεργασία των δεδομένων, η οποία περιλάμβανε έλεγχο για ελλιπείς τιμές, μετατροπή των ημερομηνιών σε κατάλληλη μορφή χρονικής σήμανσης και τυπική κανονικοποίηση των τιμών για την ενίσχυση της σταθερότητας των μοντέλων μηχανικής μάθησης.

Προκειμένου να εξασφαλιστεί μια αντιπροσωπευτική και ισορροπημένη αξιολόγηση, επιλέχθηκε ένα σύνολο ζευγών νομισμάτων που καλύπτει διαφορετικά επίπεδα μεταβλητότητας, οικονομικής σημασίας και γεωγραφικής διαφοροποίησης.

Για τις ανάγκες της παρούσας ανάλυσης επιλέχθηκαν τα εξής επτά ζεύγη νομισμάτων:

| Ζεύγος | Περιγραφή | Επιστημονικό Ενδιαφέρον |
|----------------|---------------------------|---|
| EUR/USD | Ευρώ – Δολάριο ΗΠΑ | Παγκόσμιο σημείο αναφοράς (benchmark pair) |
| EUR/GBP | Ευρώ – Στερλίνα Αγγλίας | Σταθερό ζεύγος με υψηλή συσχέτιση |
| EUR/JPY | Ευρώ – Γιεν Ιαπωνίας | Χαρακτηριστικό παράδειγμα υψηλής μεταβλητότητας |
| EUR/CHF | Ευρώ – Ελβετικό Φράγκο | Safe-haven νόμισμα με συχνές παρεμβάσεις |
| EUR/AUD | Ευρώ – Δολάριο Αυστραλίας | Συνδεδεμένο με τις αγορές εμπορευμάτων |
| EUR/CAD | Ευρώ – Δολάριο Καναδά | Επηρεάζεται από την ενεργειακή αγορά |
| EUR/CNY | Ευρώ – Γουάν Κίνας | Ιδιόμορφη δυναμική λόγω κρατικών παρεμβάσεων |

Πίνακας 3.1.1: Συναλλαγές Νομισμάτων

Η επιλογή αυτών των ζευγών έγινε προκειμένου να αξιολογηθεί η απόδοση των μοντέλων σε ένα ευρύ φάσμα πραγματικών συνθηκών αγοράς, που εκτείνεται από σταθερά και ημι-ρυθμιζόμενα έως ιδιαίτερα ευμετάβλητα περιβάλλοντα. Με αυτόν τον τρόπο, τα αποτελέσματα της μελέτης καθίστανται αντιπροσωπευτικά και εφαρμόσιμα σε ποικίλα οικονομικά πλαίσια, προσφέροντας μια ισορροπημένη και ολοκληρωμένη βάση για τη σύγκριση των πλεονεκτημάτων και αδυναμιών κάθε μοντέλου πρόβλεψης. Έτσι, η έρευνα συνδυάζει την ακαδημαϊκή αυστηρότητα με τη πρακτική συνάφεια, συμβάλλοντας σε ένα πεδίο ιδιαίτερου ενδιαφέροντος για ερευνητές, επαγγελματίες και φορείς χάραξης πολιτικής.

3.2 ΕΞΕΡΕΥΝΗΤΙΚΗ ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

Η Εξερευνητική Ανάλυση Δεδομένων (Exploratory Data Analysis – EDA) αποτελεί ένα θεμελιώδες στάδιο για την κατανόηση της δομής, των προτύπων και της συμπεριφοράς που εμφανίζουν οι χρηματοοικονομικές χρονοσειρές που χρησιμοποιούνται στην παρούσα μελέτη. Στο πλαίσιο της πρόβλεψης συναλλαγματικών ισοτιμιών, η EDA διαδραματίζει καθοριστικό ρόλο, καθώς αποκαλύπτει πώς εξελίσσονται οι ισοτιμίες με την πάροδο του χρόνου και αναδεικνύει σημαντικά χαρακτηριστικά όπως τάσεις, μεταβλητότητα και ασυνήθιστα γεγονότα τα οποία ενδέχεται να επηρεάσουν τα αποτελέσματα των προβλέψεων. Με την προσεκτική εξέταση των επιλεγμένων ζευγών νομισμάτων πριν από την εφαρμογή των μοντέλων LSTM και Lag-Llama, λαμβάνονται πιο τεκμηριωμένες αποφάσεις σχετικά με τη μεθοδολογία και ενισχύεται η ικανότητα ερμηνείας των πλεονεκτημάτων και των περιορισμών κάθε μοντέλου. Με αυτόν τον τρόπο, η ανάλυση δεν περιορίζεται στην τυφλή εφαρμογή προηγμένων τεχνικών, αλλά βασίζεται σε μια ουσιαστική κατανόηση των ίδιων των δεδομένων.

Στο πλαίσιο αυτής της εργασίας, η EDA επικεντρώνεται στα επτά ζεύγη νομισμάτων που παρουσιάστηκαν στην Ενότητα 3.1 και εξετάζει διεξοδικά ορισμένες κρίσιμες πτυχές: τις μακροχρόνιες τάσεις, τις ημερήσιες μεταβολές των αποδόσεων, τις περιόδους υψηλής μεταβλητότητας, τις σχέσεις μεταξύ διαφορετικών νομισματικών ζευγών και τις επιδράσεις σημαντικών οικονομικών γεγονότων. Η ολοκληρωμένη αυτή ανάλυση θέτει τα θεμέλια για την εφαρμογή των μοντέλων που ακολουθεί, ενώ παράλληλα αναδεικνύει τις πραγματικές προκλήσεις που καλούνται να αντιμετωπίσουν τα σύγχρονα μοντέλα μηχανικής μάθησης στο απρόβλεπτο περιβάλλον της αγοράς Forex. Μέσα από τον συνδυασμό λεπτομερούς εξερεύνησης των δεδομένων και προηγμένης μοντελοποίησης, η παρούσα έρευνα επιδιώκει να προσφέρει αποτελέσματα που είναι ταυτόχρονα επιστημονικά τεκμηριωμένα και πρακτικά χρήσιμα.

3.2.1 Μακροχρόνιες τάσεις των συναλλαγματικών ισοτημιών

Η λεπτομερής εξέταση των ιστορικών μεταβολών στα επιλεγμένα ζεύγη νομισμάτων αναδεικνύει τον δυναμικό χαρακτήρα της αγοράς συναλλάγματος (Forex). Η οπτικοποίηση των

ιστορικών δεδομένων δείχνει ότι κάθε ζεύγος ακολουθεί διακριτά πρότυπα κίνησης, τα οποία συχνά επηρεάζονται από οικονομικές τάσεις, μεταβολές στη νομισματική πολιτική και διεθνή γεγονότα. Η ανάλυση αυτών των μακροχρόνιων μοτίβων αποκαλύπτει τόσο περιόδους σταθερότητας όσο και φάσεις έντονης μεταβλητότητας. Τα ευρήματα αυτά υπογραμμίζουν την πολυπλοκότητα της πρόβλεψης συναλλαγματικών ισοτιμιών, η οποία απαιτεί όχι μόνο προηγμένα τεχνικά μοντέλα αλλά και ουσιαστική κατανόηση των ευρύτερων συνθηκών της αγοράς.

Τα επτά ζεύγη νομισμάτων που εξετάζονται στην παρούσα μελέτη παρουσιάζουν ορισμένα χαρακτηριστικά μοτίβα:

- Ζεύγη όπως τα EUR/GBP και EUR/CHF εμφανίζουν σχετικά ομαλές και σταθερές μακροχρόνιες τάσεις.
- Αντίθετα, τα EUR/JPY και EUR/AUD παρουσιάζουν συχνότερες και πιο έντονες διακυμάνσεις.
- Σύμφωνα με τη σχετική βιβλιογραφία, σημαντικά διεθνή γεγονότα ενδέχεται να συνδέονται με αυξημένη μεταβλητότητα ή αλλαγές στη συμπεριφορά των συναλλαγματικών ισοτιμιών. Αν και η παρούσα εργασία δεν εξετάζει άμεσα τις επιδράσεις αυτών των γεγονότων στα συγκεκριμένα ζεύγη, αναγνωρίζεται ότι αποτελούν σημαντικό παράγοντα στη μακροχρόνια ανάλυση της αγοράς συναλλαγμάτων.

Οι παρατηρήσεις αυτές δείχνουν ότι τα μοντέλα πρόβλεψης πρέπει να μπορούν να προσαρμόζονται σε διαφορετικά καθεστώτα αγοράς. Οι μακροχρόνιες τάσεις δεν περιορίζονται σε απλά εποχικά μοτίβα: συχνά αντικατοπτρίζουν βαθύτερους οικονομικούς μηχανισμούς, τους οποίους απλούστερα μοντέλα δυσκολεύονται να αποτυπώσουν. Για τον λόγο αυτό, πιο προηγμένες τεχνικές, όπως τα LSTM δίκτυα και το foundation model LLaMA έχουν ιδιαίτερη αξία σε ερευνητικό πλαίσιο, καθώς μπορούν να εντοπίζουν πιο σύνθετες χρονικές εξαρτήσεις και να μαθαίνουν με μεγαλύτερη ευελιξία από τη δυναμική των ιστορικών δεδομένων.

Η προσεκτική μελέτη αυτών των μακροχρόνιων κινήσεων επιτρέπει στη διερευνητική ανάλυση δεδομένων (EDA) να θέσει ένα ισχυρό υπόβαθρο για την εξέταση της μεταβλητότητας, των αποδόσεων και των συσχετίσεων μεταξύ διαφορετικών νομισματικών ζευγών. Αυτά τα

στοιχεία είναι κρίσιμα για την κατανόηση της λειτουργίας και της απόδοσης των μοντέλων πρόβλεψης που χρησιμοποιούνται στην παρούσα διπλωματική εργασία.

3.2.2 Ημερήσιες αποδόσεις και μεταβλητότητα

Η βραχυπρόθεσμη συμπεριφορά των συναλλαγματικών ισοτιμιών εξετάζεται συνήθως μέσω των ημερήσιων αποδόσεων, δηλαδή των μεταβολών που σημειώνονται από τη μία ημέρα στην επόμενη. Η προσέγγιση αυτή, η οποία χρησιμοποιείται ευρέως στη χρηματοοικονομική έρευνα, αποτυπώνει τόσο μικρές διακυμάνσεις όσο και σημαντικότερες κινήσεις της αγοράς, προσφέροντας μια συνολική εικόνα των βραχυχρόνιων τάσεων.

Η ανάλυση των ημερήσιων αποδόσεων αναδεικνύει ορισμένα βασικά χαρακτηριστικά του περιβάλλοντος στο οποίο λειτουργούν τα μοντέλα πρόβλεψης:

- Τα περισσότερα ζεύγη νομισμάτων παρουσιάζουν μικρές ημερήσιες μεταβολές που παραμένουν κοντά στο μηδέν. Αυτό σημαίνει ότι, βραχυπρόθεσμα, δεν εμφανίζονται έντονες ανοδικές ή καθοδικές τάσεις και οι αγορές μεταβάλλονται συνήθως με ήπιο ρυθμό.
- Περίοδοι αυξημένης μεταβλητότητας συχνά εμφανίζονται σε «συστάδες», όπου ημέρες με μεγάλες διακυμάνσεις ακολουθούνται από περαιτέρω ασταθείς περιόδους. Αυτό το μοτίβο καθιστά την πρόβλεψη πιο απαιτητική, καθώς τα μοντέλα πρέπει να προσαρμόζονται σε εκτεταμένα διαστήματα απρόβλεπτης αγοράς, ειδικά μετά από οικονομικές ανακοινώσεις ή ειδησεογραφικά γεγονότα που επηρεάζουν τη συγκεκριμένη αγορά. Τέτοιες ξαφνικές μεταβολές δημιουργούν ακανόνιστα πρότυπα, τα οποία είναι δύσκολο να αποτυπωθούν από μοντέλα που βασίζονται σε υποθέσεις ομαλότερης συμπεριφοράς.
- Το επίπεδο της βραχυπρόθεσμης αστάθειας δεν είναι ίδιο σε όλα τα ζεύγη νομισμάτων. Για παράδειγμα, τα EUR/JPY και EUR/AUD εμφανίζουν πιο έντονες διακυμάνσεις, ενώ τα EUR/GBP και EUR/CHF χαρακτηρίζονται από μεγαλύτερη σταθερότητα.

Η κατανόηση αυτών των ημερήσιων μεταβολών είναι κρίσιμη για την αξιολόγηση της απόδοσης των μοντέλων πρόβλεψης. Παραδοσιακές μέθοδοι, αλλά και πιο σύγχρονες αρχιτεκτονικές όπως τα LSTM, συχνά δυσκολεύονται να ανταποκριθούν σε περιόδους έντονης ή απρόβλεπτης μεταβλητότητας. Αντίθετα, τα foundation models όπως το Lag-Llama, τα οποία έχουν εκπαιδευτεί σε ένα ευρύ φάσμα ετερογενών χρονοσειρών, ενδέχεται να διαχειρίζονται καλύτερα τα σύνθετα αυτά μοτίβα. Συνεπώς, η εξέταση των ημερήσιων αποδόσεων και της

μεταβλητήτης αποτελεί ένα σημαντικό στάδιο που προετοιμάζει το έδαφος για τη σύγκριση των μοντέλων στα επόμενα κεφάλαια.

Τα ακόλουθα διαγράμματα αποτυπώνουν τις χρονικές μεταβολές επιλεγμένων ζευγών νομισμάτων, όπως αυτές προέκυψαν από τη διερευνητική ανάλυση δεδομένων (EDA). Οι οπτικοποιήσεις αυτές προσφέρουν περαιτέρω διευκρίνιση των προηγούμενων παρατηρήσεων.



Διάγραμμα 3.2.1: EUR – GBP Long Term Trend

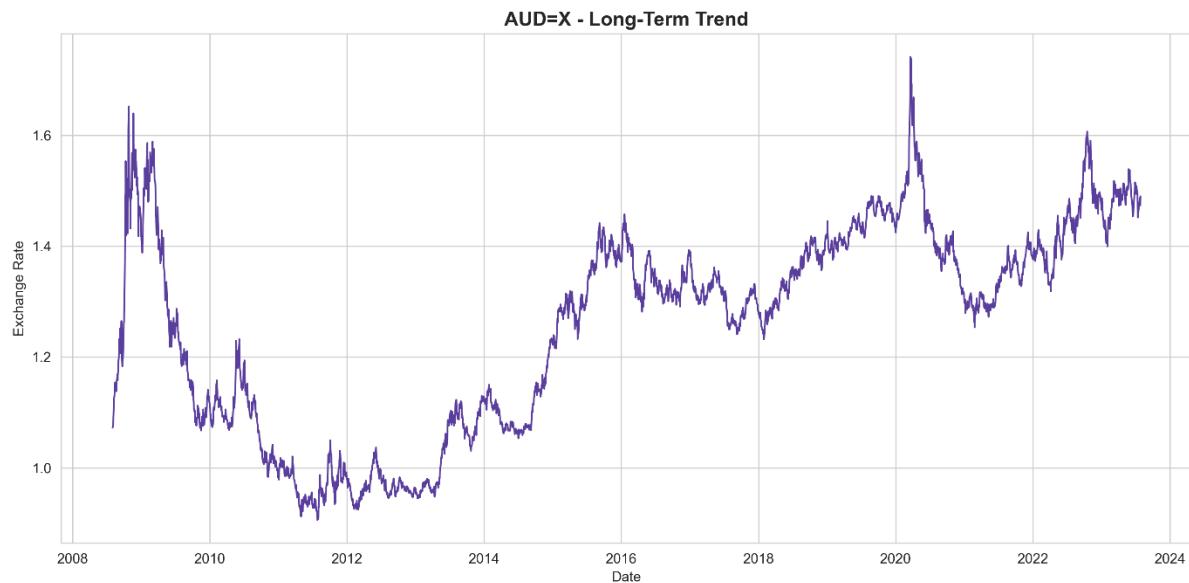
Το διάγραμμα της ισοτιμίας EUR/GBP δείχνει ότι το συγκεκριμένο ζεύγος ακολούθησε μια αρκετά σταθερή πορεία την περίοδο 2008–2024, χωρίς πολλές απότομες ή ξαφνικές μεταβολές. Παρατηρούνται ορισμένες μέτριες αυξομειώσεις, με την πιο εμφανή ανοδική τάση να διαρκεί έως περίπου το 2015–2016, μετά την οποία η ισοτιμία παρουσιάζει συχνότερες διακυμάνσεις.

Συνολικά, αυτό το μοτίβο υποδεικνύει χαμηλή έως μέτρια μεταβλητήτα, γεγονός που σημαίνει ότι το ζεύγος EUR/GBP είναι γενικά ευκολότερο να προβλεφθεί σε σχέση με άλλα πιο ασταθή νομίσματα. Για τον λόγο αυτό, επιλέγεται συχνά ως παράδειγμα σταθερού ζεύγους κατά τη σύγκριση μοντέλων πρόβλεψης στο πλαίσιο αυτής της πτυχιακής εργασίας.



Διάγραμμα 3.2.2: EUR – JPY Long Term Trend

Σε αντίθεση με το EUR/GBP, η ισοτιμία EUR/JPY εμφανίζεται πολύ πιο απρόβλεπτη κατά τη διάρκεια της εξεταζόμενης περιόδου. Το διάγραμμα δείχνει πολλές μεγάλες αυξομειώσεις, ιδιαίτερα μετά το 2012, με την ισοτιμία να κινείται ανοδικά αλλά ταυτόχρονα να παρουσιάζει απότομες κορυφώσεις και διορθώσεις. Για τον λόγο αυτό, το EUR/JPY αποτελεί χαρακτηριστικό παράδειγμα χρονοσειράς δύσκολης στην πρόβλεψη, κάτι που δημιουργεί σημαντικές προκλήσεις για τα μοντέλα πρόβλεψης, ειδικά όταν οι μεταβολές είναι συνεχείς και έντονες για μεγάλα χρονικά διαστήματα. Αυτό καθιστά το EUR/JPY ιδιαίτερα ενδιαφέρον για την παρούσα πτυχιακή εργασία, καθώς αναδεικνύει τα σημεία όπου τα παραδοσιακά μοντέλα ενδέχεται να αποδίδουν λιγότερο αποτελεσματικά.



Διάγραμμα 3.2.3: AUD – USD Long Term Trend

Η ισοτιμία AUD/USD παρουσιάζει πολλές αυξομειώσεις την περίοδο 2008–2024. Στα αρχικά χρόνια, η ισοτιμία αυξάνεται γρήγορα και στη συνέχεια πέφτει εξίσου απότομα. Μετά από αυτό, παραμένει σε χαμηλότερα επίπεδα για κάποιο διάστημα, ακολουθώντας πιο ομαλή πορεία, μέχρι να αρχίσει να ανακάμπτει γύρω στο 2016–2017. Στα επόμενα χρόνια, το διάγραμμα εμφανίζει μεγαλύτερες και συχνότερες διακυμάνσεις. Αυτό το μοτίβο καθιστά το AUD/USD δύσκολο στη μοντελοποίηση και πρόβλεψη, ειδικά σε σύγκριση με πιο σταθερά ζεύγη όπως το EUR/GBP, και δείχνει γιατί η χρήση πιο προηγμένων μοντέλων πρόβλεψης είναι σημαντική για την παρούσα πτυχιακή εργασία.

3.2.3 Συσχέτιση μεταξύ ζευγών νομισμάτων

Η ανάλυση της συσχέτισης μεταξύ διαφορετικών ζευγών νομισμάτων αποκαλύπτει τον βαθμό στον οποίο οι τιμές τους κινούνται παράλληλα ή ανεξάρτητα. Παρότι οι συναλλαγματικές ισοτιμίες επηρεάζονται από πολλούς εξωτερικούς παράγοντες, η ανάλυση συσχέτισης αναδεικνύει υποκείμενα μοτίβα και εντοπίζει ζεύγη που είναι πιο απαιτητικά ως προς την πρόβλεψη.

Ορισμένα σαφή πρότυπα προκύπτουν από τη συγκεκριμένη ανάλυση. Τα ευρωπαϊκά ζεύγη, όπως τα EUR/GBP και EUR/CHF, παρουσιάζουν συνήθως ισχυρή θετική συσχέτιση λόγω των στενά συνδεδεμένων οικονομιών τους. Αντίθετα, ζεύγη όπως τα EUR/AUD και EUR/CAD εμφανίζουν ασθενέστερη συσχέτιση, γεγονός που αντανακλά την επίδραση διαφορετικών οικονομικών παραγόντων. Ορισμένα ζεύγη, όπως το EUR/CNY, κινούνται σε μεγάλο βαθμό ανεξάρτητα και παρουσιάζουν περιορισμένη συσχέτιση με τα υπόλοιπα.

Η πληροφορία αυτή είναι ιδιαίτερα χρήσιμη από πλευράς μοντελοποίησης. Ζεύγη με υψηλή συσχέτιση τείνουν να εμφανίζουν πιο σταθερές και προβλέψιμες δομές, επιτρέποντας στα μοντέλα να εντοπίζουν τα βασικά μοτίβα πιο αποτελεσματικά. Αντίθετα, ζεύγη με χαμηλή ή ασταθή συσχέτιση, ή ζεύγη που υπόκεινται σε έντονα εξωγενή σοκ, είναι πιο περίπλοκα και δυσκολότερα στην πρόβλεψη. Η κατανόηση αυτών των σχέσεων παρέχει ουσιαστικό υπόβαθρο για την αξιολόγηση της απόδοσης των μοντέλων LSTM και Lag – Llama στα επόμενα κεφάλαια.

3.2.4 Ιδιομορφίες της κατανομής αποδόσεων

Οι ημερήσιες διακυμάνσεις στις συναλλαγματικές ισοτιμίες παρουσιάζουν χαρακτηριστικά που διαφοροποιούν τις χρονοσειρές Forex από πιο σταθερά ή κανονικά κατανεμημένα δεδομένα. Οι αποδόσεις εμφανίζουν συχνότερες ακραίες μεταβολές σε σχέση με μια κανονική κατανομή, συχνές μικρές μεταβολές γύρω από το μηδέν και, κατά περίπτωση, έντονες διαφορές μεταξύ ανοδικών και καθοδικών κινήσεων. Επιπλέον, η μεταβλητότητα δεν είναι σταθερή με την πάροδο του χρόνου, αλλά εναλλάσσεται μεταξύ περιόδων σχετικής σταθερότητας και

περιόδων αυξημένης αστάθειας. Ξαφνικές μετατοπίσεις (regime shifts) μπορούν να μεταβάλουν απρόσμενα τη συμπεριφορά της χρονοσειράς.

Τα χαρακτηριστικά αυτά δημιουργούν σημαντικές προκλήσεις για τα μοντέλα πρόβλεψης. Μέθοδοι που βασίζονται στην κανονικότητα ή στη στασιμότητα συχνά αποτυγχάνουν να συλλάβουν την πολυπλοκότητα των πραγματικών δεδομένων Forex. Ακόμη και τα πιο εξελιγμένα μοντέλα, όπως τα LSTM, ενδέχεται να δυσκολευτούν μπροστά σε απότομες αλλαγές καθεστώτος ή σε ακραίες τιμές. Τα foundation models, όπως το Lag-Llama, τα οποία έχουν προεκπαιδευτεί σε ένα ευρύ και ετερογενές σύνολο χρονοσειρών, μπορεί να εμφανίζουν μεγαλύτερη ανθεκτικότητα σε μη γραμμικότητες και διακυμάνσεις της αγοράς.

Η κατανόηση αυτών των προτύπων και των μεταβολών τους στον χρόνο είναι καθοριστική για την αξιολόγηση της απόδοσης των μοντέλων που εξετάζονται στην παρούσα πτυχιακή. Αναδεικνύει, επίσης, γιατί η πρόβλεψη συναλλαγματικών ισοτιμιών αποτελεί μια ιδιαίτερα απαιτητική διαδικασία.

3.2.5 Σύνοψη ευρημάτων της Εξερευνητικής Ανάλυσης

Η διερευνητική ανάλυση δεδομένων (EDA) παρέχει μια ολοκληρωμένη εικόνα της πολυπλοκότητας των χρονοσειρών Forex και αναδεικνύει τις προκλήσεις που θέτουν για τα μοντέλα πρόβλεψης. Οι μακροχρόνιες τάσεις διαφοροποιούνται σημαντικά μεταξύ των ζευγών, αντανακλώντας διαφορετικά μακροοικονομικά περιβάλλοντα και εξωτερικές επιδράσεις. Αν και οι ημερήσιες μεταβολές είναι συχνά μικρές, συνοδεύονται από σημαντική βραχυπρόθεσμη μεταβλητότητα, η οποία τείνει να εμφανίζεται σε συστάδες και όχι με ομοιόμορφη κατανομή.

Τα πρότυπα συσχέτισης μεταξύ των ζευγών δεν είναι σταθερά ούτε ομοιογενή. Τα ευρωπαϊκά ζεύγη συνήθως κινούνται πιο συγχρονισμένα, ενώ νομίσματα που επηρεάζονται από αγορές εμπορευμάτων ή παρεμβάσεις πολιτικής εμφανίζουν πιο αδύναμες ή λιγότερο προβλέψιμες σχέσεις. Παράλληλα, η κατανομή των αποδόσεων αποκλίνει αισθητά από την κανονικότητα και περιλαμβάνει ακραίες τιμές, δυσχεραίνοντας περαιτέρω τη διαδικασία μοντελοποίησης. Σταδιακές και απότομες διαρθρωτικές μεταβολές στις χρονοσειρές επιβεβαιώνουν τη δυναμική φύση των διεθνών χρηματοοικονομικών αγορών.

Συνοπτικά, τα ευρήματα δείχνουν ότι τα δεδομένα Forex χαρακτηρίζονται από υψηλή πολυπλοκότητα, θόρυβο και έντονη ευαισθησία σε παγκόσμιες εξελίξεις. Συνεπώς, τα μοντέλα

πρόβλεψης πρέπει να είναι ικανά να προσαρμόζονται σε μεταβαλλόμενες συνθήκες, να αποτυπώνουν μη γραμμικά μοτίβα και να παραμένουν αξιόπιστα κατά τη διάρκεια περιόδων αυξημένης αστάθειας. Τα συμπεράσματα της EDA αποτελούν το θεμέλιο για τη διαδικασία μοντελοποίησης και τις συγκριτικές αξιολογήσεις που ακολουθούν, με ιδιαίτερη έμφαση στην απόδοση των LSTM και του foundation model Lag-Llama σε διαφορετικά και απαιτητικά χρηματοοικονομικά περιβάλλοντα.

4 ΜΕΘΟΔΟΛΟΓΙΑ

4.1 ΕΠΙΚΣΟΠΗΣΗ ΜΕΘΟΔΟΛΟΓΙΑΣ

Το παρόν κεφάλαιο παρουσιάζει τη μεθοδολογική προσέγγιση που χρησιμοποιήθηκε για τη δίκαιη και συστηματική αξιολόγηση της ικανότητας πρόβλεψης δύο διαφορετικών μοντέλων χρονοσειρών: του νευρωνικού δικτύου Long Short-Term Memory (LSTM) και του foundation model Lag-Llama. Η μεθοδολογία σχεδιάστηκε έτσι ώστε να είναι αυστηρή, διαφανής και συνεπής με τις σύγχρονες βέλτιστες πρακτικές στην ανάλυση χρονοσειρών και τη βαθιά μάθηση.

Η ερευνητική διαδικασία ακολούθησε τα ακόλουθα βασικά στάδια:

1. Συλλογή και προετοιμασία δεδομένων

Το dataset περιλαμβάνει ημερήσιες συναλλαγματικές ισοτιμίες για την περίοδο 2008 – 2023. Τα δεδομένα υποβλήθηκαν σε προσεκτικό καθαρισμό, αναδιάρθρωση και κανονικοποίηση, ώστε να καταστούν κατάλληλα για ανάλυση μέσω τεχνικών μηχανικής μάθησης.

2. Εξερευνητική Ανάλυση Δεδομένων (EDA)

Εξετάστηκαν σε βάθος οι μακροχρόνιες τάσεις, οι ημερήσιες αποδόσεις, η μεταβλητότητα, οι συσχετίσεις μεταξύ νομισματικών ζευγών και οι δομικές μεταβολές. Τα ευρήματα της EDA καθοδήγησαν κρίσιμες μεθοδολογικές επιλογές και εξασφάλισαν ότι τα πειράματα πρόβλεψης βασίζονται σε ουσιαστική κατανόηση των δεδομένων.

3. Διαχωρισμός σε σύνολα εκπαίδευσης και δοκιμής

Κάθε χρονοσειρά χωρίστηκε χρονολογικά σε training και testing set, με διατήρηση της χρονικής σειράς. Αυτή η προσέγγιση αντικατοπτρίζει ρεαλιστικές συνθήκες πρόβλεψης, καθώς δεν επιτρέπει διαρροή πληροφοριών από το μέλλον προς το παρελθόν.

4. Ανάπτυξη δύο αρχιτεκτονικών πρόβλεψης

- Το κλασικό νευρωνικό δίκτυο LSTM, ευρέως χρησιμοποιούμενο στην πρόβλεψη χρονοσειρών.

- To **Lag-Llama**, éna σύγχρονo foundation model βασισμένo σtηn αρχitektovikή Transformer, ειδικά σχεδιασμένo γia χρονοσειρές.

5. Εκπαίδευση μοντέλων και ρύθμιση υπερπαραμέτρων

To μοντέλo LSTM εκπαιδεύτηκe από tηn αρχή (from scratch), ενώ to Lag-Llama αξιολογήθηκe tόso σe zero-shot συνθήκes óso κai μe fine-tuning, ανάλογa μe to πeírama. H διπλή autή σtratηgiκή epiτrέpeι mia díkaiη ektímpet tηs aξiás tωn pretrained foundation models.

6. Aξiοlόgyηsi κai σyγkristi tηs apόdosiηs

H akríbeia tωn priblēψewon metrήθηk e mēso kathierwomēnō dēiktōn aξiοlόgyηs MAE, RMSE κai MAPE. Oi sygkrisies praigmatopoiήthekan γia óla ta epilegmena nōmismatič ūngh, wste na diafahlistei η aξiopištia κai η dūnatoteta geníkeusηs tωn apotelesemátow.

7. Ermeneia tωn apotelesemátow

Ta eurhmatata sužetountai upó tō φωs tηs σchetičs bibrliografias, me stócho tηn anádeiži tωn dūnatōn s̄mēiōn, tωn pereiorisimōn κai tηs pракtikήs chrtifmótetaç káthe montélou γia tηn priblēψe χr̄matooikonomikōw χronoseirōw se diafahretikā pereibálloonta agorás.

Sunoliká η meθodologikή autή priblēψe kathierwonei éna oloklyrhomēno κai stibaró pláisio sygkrisis dūo diafahretikōw paradeigmátow priblēψe: tou paradisiakou LSTM κai tou sygchroñou foundation model Lag-Llama. H domēnη dia dikasía ezaafalíz ei mia díkaiη, emperistatowmēnη κai akademická tekmēriowmēnη aξioloγηs sto dūnamikó κai idaietérōs apaitetikó pereibálloont tηs agorás sunallámatoç.

4.2 ΠΡΟΕΠΕΞΕΡΓΑΣΙΑ ΚΑΙ ΚΑΘΑΡΙΣΜΟΣ ΔΕΔΟΜΕΝΩΝ

Στο πλαίσιο της παρούσας εργασίας, εφαρμόστηκε μια σαφής και συστηματική διαδικασία καθαρισμού και μετασχηματισμού των δεδομένων, ώστε τόσο το LSTM όσο και το Lag-Llama να εκπαιδευτούν με συνεπή και κατάλληλα προετοιμασμένα δεδομένα. Με αυτό τον τρόπο εξασφαλίζεται μια δίκαιη και ουσιαστική σύγκριση της απόδοσής τους.

Η διαδικασία προετοιμασίας των δεδομένων περιλάμβανε τα εξής βασικά βήματα:

- 1 Πρώτον, η στήλη της ημερομηνίας μετατράπηκε σε τυποποιημένη μορφή και χρησιμοποιήθηκε ως χρονολογικός δείκτης για κάθε σειρά τιμών. Με αυτό τον τρόπο διατηρήθηκε η σωστή χρονική σειρά και διασφαλίστηκε ότι όλες οι χρονικές πράξεις εκτελούνται με ορθό τρόπο.
- 2 Στη συνέχεια, πραγματοποιήθηκε έλεγχος για τυχόν ελλιπείς τιμές σε όλα τα ζεύγη νομισμάτων. Δεδομένου ότι το dataset ενημερωνόταν καθημερινά και ήταν καλά οργανωμένο, δεν παρατηρήθηκαν ουσιαστικά κενά, επομένως δεν απαιτήθηκαν μέθοδοι συμπλήρωσης. Η απουσία ελλιπών τιμών ενισχύει τη σταθερότητα των μοντέλων και αποφεύγει την ανάγκη για τεχνητές παρεμβάσεις.
- 3 Από το πλήρες σύνολο δεδομένων επιλέχθηκαν επτά ζεύγη νομισμάτων με βάση τη χρηματοοικονομική σημασία τους και τα διαφορετικά επίπεδα μεταβλητότητάς τους. Η διαφοροποίηση αυτή επιτρέπει την αξιολόγηση της ικανότητας των μοντέλων να προσαρμόζονται σε ένα εύρος πραγματικών συνθηκών της αγοράς.
- 4 Επιπλέον, επιβεβαιώθηκε ότι τα δεδομένα διατηρούν σταθερή ημερήσια συχνότητα, με εξαίρεση τα Σαββατοκύριακα κατά τα οποία οι αγορές Forex είναι κλειστές. Η ομοιομορφία αυτή είναι ζωτικής σημασίας, καθώς τα μοντέλα πρόβλεψης απαιτούν δεδομένα με κανονικά χρονικά διαστήματα.
- 5 Στη συνέχεια εφαρμόστηκε διαδικασία κανονικοποίησης, ώστε όλες οι τιμές νομισμάτων να κλιμακωθούν στο ίδιο εύρος (με τεχνικές όπως Min–Max ή Standard scaling). Η κανονικοποίηση συμβάλλει στη σταθερότερη εκπαίδευση, κάτι ιδιαίτερα σημαντικό για τα LSTM, τα οποία είναι ευαίσθητα σε μεγάλες αριθμητικές διακυμάνσεις. Παρόλο που το Lag-Llama είναι πιο ανθεκτικό λόγω της προεκπαίδευσής του, η τυποποίηση των εισόδων βελτιώνει την απόδοση και των δύο μοντέλων.

6 Τέλος, υπολογίστηκαν πρόσθετες μεταβλητές, όπως οι ημερήσιες αποδόσεις, οι κυλιόμενοι μέσοι όροι και οι μετρήσεις μεταβλητών της. Οι μεταβλητές αυτές χρησιμοποιήθηκαν κυρίως για τη βαθύτερη κατανόηση της συμπεριφοράς των χρονοσειρών και όχι απαραίτητα ως απευθείας είσοδοι στα μοντέλα πρόβλεψης.

Συμπερασματικά, η διαδικασία προ επεξεργασίας διασφάλισε ότι το dataset είναι καθαρό, συνεπές και κατάλληλο για δίκαιη και αξιόπιστη σύγκριση των μοντέλων LSTM και Llama. Με ένα σταθερό και προσεκτικά προετοιμασμένο σύνολο δεδομένων, τα επόμενα στάδια μοντελοποίησης και αξιολόγησης βασίζονται σε στιβαρή και τεκμηριωμένη βάση.

4.3 ΔΙΑΧΩΡΙΣΜΟΣ ΕΚΠΑΙΔΕΥΣΗΣ – ΕΛΕΓΧΟΥ (TRAIN – TEST SPLIT)

Ο διαχωρισμός του dataset σε σύνολο εκπαίδευσης και σύνολο ελέγχου αποτελεί βασικό βήμα σε κάθε έργο πρόβλεψης χρονοσειρών. Σε αντίθεση με άλλους τύπους δεδομένων, οι χρονοσειρές δεν μπορούν να αναμιχθούν τυχαία, επειδή η χρονική σειρά των γεγονότων έχει σημασία. Διατηρώντας τα δεδομένα στην αρχική τους χρονική σειρά, εξασφαλίζουμε ότι το μοντέλο μαθαίνει μόνο από το παρελθόν και αξιολογείται σε μελλοντικά δεδομένα που δεν έχει ξαναδεί όπως ακριβώς συμβαίνει και σε πραγματικές συνθήκες πρόβλεψης.

Για τους σκοπούς της παρούσας εργασίας, ο διαχωρισμός εκπαίδευσης–ελέγχου σχεδιάστηκε λαμβάνοντας υπόψη τα ακόλουθα:

- **Χρονικός διαχωρισμός αντί τυχαίας δειγματοληψίας:** Κάθε ζεύγος νομισμάτων χωρίστηκε με βάση τις πραγματικές ημερομηνίες, χωρίς καμία αναδιάταξη. Με αυτόν τον τρόπο, το μοντέλο εκπαιδεύεται πάντοτε σε παρελθοντικά δεδομένα και αξιολογείται σε τιμές που δεν έχει ξαναδεί.
- **Δομή train – test:** Το μεγαλύτερο μέρος των παλαιότερων δεδομένων χρησιμοποιήθηκε για εκπαίδευση, ενώ το πιο πρόσφατο τμήμα κάθε χρονοσειράς κρατήθηκε για έλεγχο. Αυτό αντικατοπτρίζει τον τρόπο με τον οποίο γίνεται η πρόβλεψη στην πράξη, όπου τα μελλοντικά δεδομένα είναι πάντα άγνωστα.
- **Επαρκές μέγεθος test set για αξιόπιστη αξιολόγηση:** Επιλέχθηκε μέγεθος test set που περιλαμβάνει αρκετά σημεία ώστε να μπορούν να μετρηθούν τα σφάλματα με αξιοπιστία, αλλά όχι τόσο μεγάλο ώστε να μειώσει υπερβολικά το σύνολο εκπαίδευσης.

- **Συνεπής εφαρμογή σε όλα τα ζεύγη νομισμάτων:** Η ίδια διαδικασία διαχωρισμού εφαρμόστηκε σε όλα τα επτά ζεύγη νομισμάτων, εξασφαλίζοντας δίκαιη σύγκριση μεταξύ μοντέλων και πειραμάτων.
- **Ρεαλιστική αναπαράσταση συνθηκών αγοράς:** Η χρήση της χρονικής πληροφορίας ως βάση για τον διαχωρισμό αντικατοπτρίζει τον πραγματικό τρόπο με τον οποίο γίνεται η πρόβλεψη στις χρηματοοικονομικές αγορές, όπου οι αποφάσεις πρέπει να στηρίζονται αποκλειστικά σε ιστορικά δεδομένα.

Συνοψίζοντας, αυτός ο τρόπος διαχωρισμού αποτρέπει τη διαρροή πληροφορίας από το μέλλον προς το παρελθόν, διατηρεί τη χρονική δομή των δεδομένων και δημιουργεί μια δίκαιη και αξιόπιστη βάση για τη σύγκριση της απόδοσης των μοντέλων LSTM και Lag-Llama.

4.4 ΑΡΧΙΤΕΚΤΟΝΙΚΗ ΚΑΙ ΕΚΠΑΙΔΕΥΣΗ LSTM

To Long Short-Term Memory (LSTM) νευρωνικό δίκτυο αποτελεί μία από τις πιο δημοφιλείς επιλογές για την πρόβλεψη χρονοσειρών, καθώς έχει τη δυνατότητα να εντοπίζει πρότυπα που εκτείνονται σε μεγάλο χρονικό διάστημα. Στην παρούσα εργασία, το LSTM χρησιμοποιείται ως μοντέλο αναφοράς (baseline), προκειμένου να αξιολογηθεί η απόδοσή του σε σύγκριση με το foundation model Lag-Llama. Η αρχιτεκτονική και η διαδικασία εκπαίδευσης του LSTM σχεδιάστηκαν έτσι ώστε να είναι σαφείς, αξιόπιστες και αναπαραγώγιμες, εξασφαλίζοντας δίκαιη και ουσιαστική σύγκριση με το Lag-Llama.

Το LSTM μοντέλο που αναπτύχθηκε σε αυτή τη μελέτη ακολουθεί μια απλή και ευρέως αποδεκτή αρχιτεκτονική:

- **Δομή εισόδου:** Κάθε μοντέλο λαμβάνει ως είσοδο ένα κινούμενο παράθυρο προηγούμενων τιμών συναλλαγματικών ισοτιμιών. Αυτή η μορφή εισόδου επιτρέπει στο LSTM να μάθει πώς εξελίσσονται οι ισοτιμίες μέσα στον χρόνο.
- **LSTM layers:** Χρησιμοποιείται μία μόνο LSTM layer με κατάλληλο αριθμό κρυφών μονάδων, ικανή να αποτυπώσει τα βασικά μοτίβα κάθε ζεύγους νομισμάτων. Η αρχιτεκτονική διατηρήθηκε σκόπιμα απλή ώστε να περιοριστεί ο κίνδυνος υπερεκπαίδευσης και να παραμείνει εύκολη στην ερμηνεία.
- **Dense output layer:** Η έξοδος του LSTM περνά από ένα πλήρως συνδεδεμένο (dense) επίπεδο, το οποίο παράγει την τελική πρόβλεψη για την επόμενη ημέρα.

- **Συναρτήσεις ενεργοποίησης και απώλειας:** Η εκπαίδευση πραγματοποιείται με χρήση της συνάρτησης απώλειας Mean Squared Error (MSE), η οποία αποτελεί τυπική επιλογή για προβλήματα παλινδρόμησης. Ο βελτιστοποιητής Adam επιλέχθηκε λόγω της σταθερότητας και της αποτελεσματικότητάς του στην εκπαίδευση επαναλαμβανόμενων νευρωνικών δικτύων.

Για μια αποτελεσματική εκπαίδευση του μοντέλου, εφαρμόστηκαν τα εξής βήματα:

- **Κανονικοποίηση τιμών εισόδου:** Όλες οι τιμές των ισοτιμιών κανονικοποιήθηκαν πριν από την εκπαίδευση, ώστε να βρίσκονται στο ίδιο εύρος και να μην επηρεάζεται η μάθηση από διαφορές κλίμακας.
- **Δημιουργία παραθύρων (window generation):** Τα δεδομένα μετατράπηκαν σε επικαλυπτόμενα ζεύγη εισόδου–εξόδου, όπου το μοντέλο μαθαίνει να προβλέπει την τιμή της επόμενης ημέρας βασισμένο σε ένα συγκεκριμένο αριθμό προηγούμενων ημερήσιων τιμών.
- **Ρυθμίσεις εκπαίδευσης:** Το μοντέλο εκπαιδεύτηκε για επαρκή αριθμό εποχών (epochs), ενώ χρησιμοποιήθηκε early stopping για την αποφυγή υπερεκπαίδευσης. Ένα μέρος των δεδομένων εκπαίδευσης χρησιμοποιήθηκε ως σύνολο επικύρωσης (validation set) για την παρακολούθηση της προόδου μάθησης.
- **Ενίσχυση αξιοπιστίας:** Η διαδικασία εκπαίδευσης επαναλήφθηκε όπου ήταν απαραίτητο, ενώ οι υπερπαράμετροι τροποποιήθηκαν βάσει αρχικών δοκιμών. Η πολυπλοκότητα διατηρήθηκε χαμηλή σκόπιμα, για να είναι η σύγκριση με το Lag-Llama καθαρή και δίκαιη.

Με αυτή τη διάταξη, το LSTM baseline μοντέλο είναι ταυτόχρονα αυστηρό και εύκολο στην κατανόηση, επιτρέποντας μια καθαρή και αντικειμενική σύγκριση με το πιο σύγχρονο και προεκπαιδευμένο Lag-Llama. Στόχος δεν είναι η απόλυτη βελτιστοποίηση του LSTM, αλλά η αξιολόγηση της επίδοσής του σε ρεαλιστικές συνθήκες πρόβλεψης σε σύγκριση με ένα state-of-the-art foundation model.

4.5 ΡΥΘΜΙΣΗ ΚΑΙ ΔΙΑΔΙΚΑΣΙΑ ΠΡΟΒΛΕΒΗΣ ΜΕ LAG-LLAMA

Το μοντέλο Lag-Llama αποτελεί μια σύγχρονη εξέλιξη στον χώρο της πρόβλεψης χρονοσειρών. Σε αντίθεση με τα παραδοσιακά νευρωνικά δίκτυα, όπως το LSTM, τα οποία απαιτούν εκπαίδευση από την αρχή για κάθε νέο dataset, το Lag-Llama είναι ένα προεκπαιδευμένο μοντέλο σχεδιασμένο ειδικά για αριθμητικά δεδομένα. Μπορεί να πραγματοποιήσει προβλέψεις είτε άμεσα (zero-shot) είτε μετά από ελάχιστη πρόσθετη εκπαίδευση (fine-tuning). Στην παρούσα εργασία, το Lag-Llama εξετάζεται και στις δύο περιπτώσεις, ώστε να αξιολογηθεί η αποτελεσματικότητα της προσέγγισης των foundation models σε πραγματικά δεδομένα Forex.

Η διαδικασία ρύθμισης και χρήσης του Lag-Llama στην παρούσα μελέτη περιλαμβάνει τα ακόλουθα βασικά στοιχεία:

- **Έκδοση μοντέλου και αρχιτεκτονική:** Χρησιμοποιείται η διαθέσιμη δημόσια έκδοση Lag-Llama “small”, η οποία βασίζεται σε αρχιτεκτονική Transformer encoder. Το συγκεκριμένο μοντέλο προσφέρει καλή ισορροπία μεταξύ ακρίβειας και υπολογιστικής ταχύτητας, γεγονός που το καθιστά κατάλληλο για ακαδημαϊκές εφαρμογές.
- **Zero-shot αξιολόγηση:** Στη zero – shot λειτουργία, το μοντέλο εφαρμόζεται στο Forex dataset χωρίς καμία επιπλέον εκπαίδευση. Αυτό επιτρέπει την αξιολόγηση της ικανότητας γενίκευσης της προεκπαιδευμένης γνώσης σε νέα ζεύγη νομισμάτων και αποτελεί ισχυρό baseline για την πρακτική χρησιμότητα των foundation models.
- **Διαδικασία fine-tuning:** Σε ορισμένα πειράματα, το Lag-Llama υφίσταται fine – tuning στο training set κάθε χρονοσειράς. Πραγματοποιούνται λίγες μόνο εποχές εκπαίδευσης, ενημερώνεται μόνο μέρος των παραμέτρων του μοντέλου, χρησιμοποιούνται χαμηλά learning rates για αποφυγή υπερεκπαίδευσης. Με αυτό το σχήμα εξετάζεται κατά πόσο η ελάχιστη προσαρμογή μπορεί να βελτιώσει τα αποτελέσματα σε σχέση με τη zero-shot χρήση.
- **Διαμόρφωση πρόβλεψης:** Για δίκαιη σύγκριση με το LSTM: κάθε ζεύγος νομισμάτων προβλέπεται μία ημέρα μπροστά (one – step ahead), εφαρμόζεται ο ίδιος διαχωρισμός train – test παράγονται προβλέψεις για όλες τις ημέρες του test set.

- **Υπολογιστικό περιβάλλον:** Όπου ήταν εφικτό, οι δοκιμές με Lag-Llama εκτελέστηκαν με χρήση GPU, καθώς τα Transformer μοντέλα επωφελούνται σημαντικά από παράλληλη επεξεργασία. Η χρήση της “small” έκδοσης διασφαλίζει ότι η εκπαίδευση και η πρόβλεψη παραμένουν υπολογιστικά διαχειρίσιμες στο πλαίσιο μιας μεταπτυχιακής εργασίας.

Με τη χρήση του Lag-Llama τόσο σε zero – shot όσο και σε fine – tuned μορφή, η εργασία αυτή προσφέρει μια ολοκληρωμένη σύγκριση μεταξύ των κλασικών τεχνικών βαθιάς μάθησης και των σύγχρονων foundation models. Η προσέγγιση αυτή αναδεικνύει όχι μόνο την προβλεπτική ικανότητα του Lag-Llama, αλλά και την ευελιξία, την αποδοτικότητα και την πρακτική του αξία για την πρόβλεψη πολύπλοκων και δυναμικών χρηματοοικονομικών χρονοσειρών.

4.6 ΜΕΤΡΙΚΕΣ ΑΞΙΟΛΟΓΗΣΗΣ

Για να γίνει μια δίκαιη και ολοκληρωμένη σύγκριση της απόδοσης των μοντέλων Long Short-Term Memory (LSTM) και Lag-Llama στην πρόβλεψη μελλοντικών τιμών, η παρούσα εργασία χρησιμοποιεί τρεις καθιερωμένες μετρικές αξιολόγησης που συναντώνται συχνά στη βιβλιογραφία των χρονοσειρών και της χρηματοοικονομικής πρόβλεψης. Κάθε μετρική αναδεικνύει διαφορετικές πτυχές του σφάλματος των προβλέψεων, επιτρέποντας να φανεί όχι μόνο πού υπερέχει κάθε μοντέλο, αλλά και σε ποιες συνθήκες ενδέχεται να υστερεί.

Οι μετρικές αξιολόγησης που χρησιμοποιήθηκαν είναι οι ακόλουθες:

- **Mean Absolute Error (MAE):** Η MAE μετρά το μέσο μέγεθος των σφαλμάτων μεταξύ των προβλεπόμενων και των πραγματικών τιμών, χωρίς να λαμβάνει υπόψη αν η πρόβλεψη ήταν υπερεκτιμημένη ή υποεκτιμημένη. Είναι εύκολη στην ερμηνεία και ιδιαίτερα χρήσιμη στη χρηματοοικονομική ανάλυση, όπου ακόμη και μικρές αποκλίσεις μπορεί να έχουν πρακτική σημασία. Μικρότερη MAE σημαίνει ότι οι προβλέψεις του μοντέλου βρίσκονται πιο κοντά στις πραγματικές τιμές.
- **Root Mean Squared Error (RMSE):** Η RMSE είναι παρόμοια με την MAE, αλλά δίνει μεγαλύτερο βάρος στα μεγάλα σφάλματα, επειδή υψώνει στο τετράγωνο τις αποκλίσεις πριν τον μέσο όρο. Έτσι, η RMSE είναι ιδιαίτερα ευαίσθητη σε ακραίες μεταβολές χαρακτηριστικό που έχει μεγάλη σημασία στις αγορές Forex, όπου οι τιμές

μπορούν να αυξηθούν ή να πέσουν απότομα. Χαμηλότερη RMSE δείχνει ότι το μοντέλο καταφέρνει να χειριστεί τόσο τις κανονικές όσο και τις ακραίες διακυμάνσεις.

- **Mean Absolute Percentage Error (MAPE):** Η MAPE εκφράζει το σφάλμα της πρόβλεψης ως ποσοστό, προσφέροντας ένα μέτρο ανεξάρτητο κλίμακας. Είναι χρήσιμη όταν συγκρίνουμε μοντέλα σε διαφορετικά ζεύγη νομισμάτων που έχουν σημαντικά διαφορετικά επίπεδα τιμών. Ωστόσο, η MAPE μπορεί να οδηγήσει σε παραπλανητικά αποτελέσματα όταν οι πραγματικές τιμές είναι πολύ κοντά στο μηδέν ή να μειονέκτημα που επισημαίνεται συχνά στη βιβλιογραφία.

Συνοπτικά, ο συνδυασμός των τριών μετρικών προσφέρει μια ολοκληρωμένη εικόνα της απόδοσης των μοντέλων:

- Η MAE δείχνει τη συνολική ακρίβεια,
- Η RMSE αναδεικνύει την ικανότητα διαχείρισης έντονης μεταβλητότητας και ακραίων γεγονότων,
- Η MAPE επιτρέπει τη σύγκριση των μοντέλων σε ποσοστιαία βάση μεταξύ διαφορετικών νομισμάτων.

Με τη χρήση και των τριών μετρικών, η αξιολόγηση γίνεται ολοκληρωμένα και με συνέπεια σε όλα τα πειράματα. Αυτό επιτρέπει μια καθαρή και δίκαιη σύγκριση του κλασικού LSTM με το πιο σύγχρονο foundation model Lag-Llama σε ρεαλιστικές χρηματοοικονομικές συνθήκες.

4.7 ΠΕΙΡΑΜΑΤΙΚΟΣ ΣΧΕΔΙΑΣΜΟΣ

Ο πειραματικός σχεδιασμός της παρούσας εργασίας διαμορφώθηκε έτσι ώστε η σύγκριση μεταξύ του μοντέλου Long Short-Term Memory (LSTM) και του foundation model Lag-Llama να είναι δίκαιη, καθαρή και επιστημονικά τεκμηριωμένη. Ο στόχος δεν περιορίζεται μόνο στο ποιο μοντέλο προβλέπει καλύτερα, αλλά επεκτείνεται και στην κατανόηση του πώς συμπεριφέρεται κάθε μοντέλο σε πραγματικές χρηματοοικονομικές συνθήκες. Για τον λόγο αυτό, οι πειραματικές διαδικασίες ακολουθούν σαφείς αρχές έρευνας και εφαρμόζουν ελεγχόμενα, ομοιόμορφα περιβάλλοντα αξιολόγησης.

Ο πειραματικός σχεδιασμός βασίζεται στα ακόλουθα κύρια σημεία:

- **Συνεπής χρήση του ίδιου dataset για όλα τα μοντέλα:** Τα δύο μοντέλα αξιολογήθηκαν στα ίδια επτά ζεύγη νομισμάτων, προερχόμενα από το ίδιο καθαρισμένο

και προεπεξεργασμένο dataset. Με αυτόν τον τρόπο, τυχόν διαφορές στην απόδοση οφείλονται στα ίδια τα μοντέλα και όχι σε αλλαγές στα δεδομένα.

- **Ενιαίο χρονικό ορίζοντα πρόβλεψης:** Και τα δύο μοντέλα κλήθηκαν να προβλέψουν την τιμή της επόμενης ημέρας (one-step-ahead forecasting), μια προσέγγιση κοινή στη βιβλιογραφία της χρηματοοικονομικής πρόβλεψης. Αυτό διευκολύνει την άμεση και ισότιμη σύγκριση των αποτελεσμάτων.
- **Δύο σενάρια αξιολόγησης για το Lag-Llama:** Για να εξεταστούν πλήρως οι δυνατότητες του foundation model, το Lag-Llama αξιολογήθηκε: **χωρίς επιπλέον εκπαίδευση (zero-shot)** και **με ελαφριά προσαρμογή στο dataset (fine-tuning)**. Αυτά τα δύο σενάρια δείχνουν αν η προεκπαίδευση αρκεί από μόνη της ή αν η πρόσθετη εκπαίδευση βελτιώνει την απόδοση.
- **Ελεγχόμενη διαδικασία εκπαίδευσης για το LSTM:** Το LSTM εκπαιδεύτηκε από την αρχή, χρησιμοποιώντας μόνο τα δεδομένα εκπαίδευσης κάθε ζεύγους νομισμάτων. Η αρχιτεκτονική του παρέμεινε απλή και τυποποιημένη ώστε να αποφευχθούν επιθετικές βελτιστοποιήσεις και να αντικατοπτρίσει τον τρόπο με τον οποίο χρησιμοποιείται συνήθως στη σχετική βιβλιογραφία.
- **Ταυτόσημος χρονικός διαχωρισμός train–test για όλα τα μοντέλα:** Ο διαχωρισμός έγινε χρονολογικά, χωρίς ανακάτεμα των δεδομένων, ώστε οι προβλέψεις να βασίζονται πάντοτε σε πραγματικά άγνωστες μελλοντικές τιμές. Το ίδιο test set χρησιμοποιήθηκε σε όλα τα πειράματα για πλήρη συγκρισιμότητα.
- **Χρήση πολλαπλών μετρικών αξιολόγησης:** Για κάθε μοντέλο και κάθε ζεύγος νομισμάτων υπολογίστηκαν οι μετρικές MAE, RMSE και MAPE. Οι τρεις αυτές μετρικές καλύπτουν την ακρίβεια, την ευαισθησία στη μεταβλητότητα και τη σύγκριση ανεξαρτήτως κλίμακας.
- **Αναπαραγωγιμότητα και συνοχή παραμέτρων:** Όλα τα πειράματα εκτελέστηκαν με σταθερούς random seeds, κοινά βήματα προεπεξεργασίας και όσο το δυνατόν πιο ομοιόμορφες ρυθμίσεις παραμέτρων, για να εξασφαλιστεί η σταθερότητα και η επαναληψιμότητα των αποτελεσμάτων.
- **Πλαίσιο συγκριτικής αξιολόγησης:** Μετά την παραγωγή των προβλέψεων, τα αποτελέσματα συγκρίθηκαν για να απαντηθούν κρίσιμα ερωτήματα, όπως: Πώς αποδίδουν τα μοντέλα σε σταθερά έναντι ιδιαίτερα ευμετάβλητων ζευγών;

Ποιο μοντέλο ανταπεξέρχεται καλύτερα σε ξαφνικές μεταβολές; Προσφέρει πραγματικό πλεονέκτημα η προεκπαίδευση ενός foundation model σε σχέση με τα παραδοσιακά μοντέλα;

Εν κατακλείδι, ο πειραματικός σχεδιασμός εξασφαλίζει ότι η σύγκριση μεταξύ LSTM και LLaMA είναι συστηματική, ισορροπημένη και σύμφωνη με τις βέλτιστες επιστημονικές πρακτικές. Έτσι, η εργασία μπορεί να εξαγάγει αξιόπιστα συμπεράσματα σχετικά με την απόδοση και τη συμπεριφορά των μοντέλων σε ένα πραγματικό, σύνθετο και συχνά απρόβλεπτο περιβάλλον όπως η αγορά Forex.

5 ΑΠΟΤΕΛΕΣΜΑΤΑ

5.1 ΣΥΝΟΠΤΙΚΗ ΠΑΡΟΥΣΙΑΣΗ ΤΩΝ ΠΕΙΡΑΜΑΤΙΚΩΝ ΑΠΟΤΕΛΕΣΜΑΤΩΝ

Το παρόν κεφάλαιο παρουσιάζει μια αναλυτική επισκόπηση των αποτελεσμάτων πρόβλεψης που προέκυψαν από τα δύο μοντέλα που εξετάζονται στη διπλωματική εργασία: το νευρωνικό δίκτυο Long Short-Term Memory (LSTM) και το foundation model Lag-Llama. Στόχος είναι η προσεκτική σύγκριση της ακρίβειας των προβλέψεών τους, αλλά και η κατανόηση του τρόπου με τον οποίο κάθε μοντέλο ανταποκρίνεται σε διαφορετικές συνθήκες της αγοράς και σε ζεύγη νομισμάτων με ιδιαίτερα χαρακτηριστικά.

Τα αποτελέσματα οργανώνονται ώστε να προσφέρουν μια καθαρή και διαφανή αξιολόγηση:

- Αρχικά παρουσιάζεται η απόδοση του μοντέλου LSTM για τα επτά επιλεγμένα ζεύγη νομισμάτων. Τα αποτελέσματα αυτά λειτουργούν ως baseline, δείχνοντας πώς αποδίδει ένα κλασικό μοντέλο βαθιάς μάθησης όταν εκπαιδεύεται απευθείας σε χρονοσειρές Forex.
- Στη συνέχεια, το μοντέλο Lag-Llama αξιολογείται στη λειτουργία zero-shot, δηλαδή πραγματοποιεί προβλέψεις χωρίς πρόσθετη εκπαίδευση για το συγκεκριμένο πρόβλημα. Αυτό μας επιτρέπει να δούμε πόσο καλά μπορούν τα προεκπαιδευμένα μοντέλα χρονοσειρών να διαχειριστούν νέα χρηματοοικονομικά δεδομένα.
- Έπειτα παρουσιάζονται τα αποτελέσματα μετά το fine-tuning του Lag-Llama σε κάθε ζεύγος νομισμάτων. Η σύγκριση αυτή δείχνει πώς ακόμη και περιορισμένη επιπλέον εκπαίδευση μπορεί να ενισχύσει την ακρίβεια του μοντέλου.
- Τέλος, μια συγκριτική ανάλυση των τριών περιπτώσεων LSTM, Lag-Llama zero-shot και Lag-Llama fine-tuned—συνοψίζει τις βασικές διαφορές, εστιάζοντας στην ακρίβεια, την ανταπόκριση σε περιόδους αυξημένης μεταβλητότητας, την ευαισθησία σε ακραία γεγονότα και τη συνολική ανθεκτικότητα των μοντέλων σε διαφορετικά καθεστώτα αγοράς.

Η αξιολόγηση βασίζεται σε τρεις ευρέως χρησιμοποιούμενους δείκτες (MAE, RMSE και MAPE), ώστε να παρασχεθεί μια πλήρης εικόνα της απόδοσης των μοντέλων. Επιπλέον,

περιλαμβάνονται γραφήματα και διαγράμματα σφαλμάτων, τα οποία βοηθούν στην κατανόηση του τρόπου με τον οποίο τα μοντέλα παρακολουθούν τις πραγματικές μεταβολές της αγοράς.

Συνοπτικά, το κεφάλαιο αυτό θέτει τα θεμέλια για την κατανόηση των πλεονεκτημάτων και των περιορισμών των παραδοσιακών μοντέλων βαθιάς μάθησης σε σύγκριση με τα σύγχρονα foundation models στην πρόβλεψη συναλλαγματικών ισοτιμιών. Τα αποτελέσματα συμβάλλουν ουσιαστικά στη συζήτηση που ακολουθεί στο Κεφάλαιο 6.

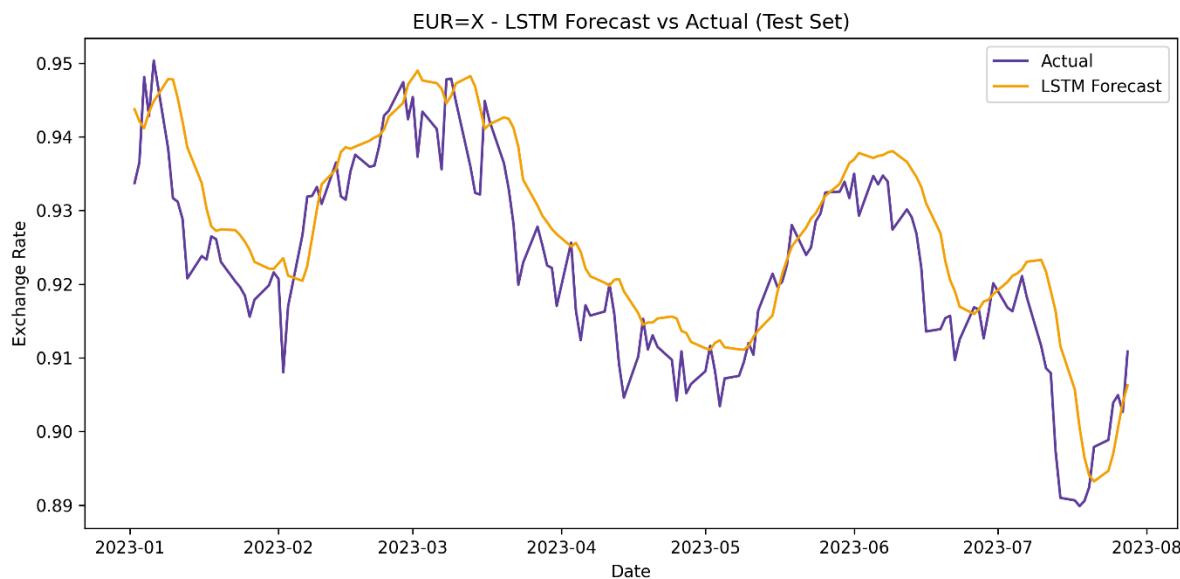
| CURRENCY PAIR | MAE | RMSE | MAPE |
|---------------|----------|----------|-------|
| AUD=X | 0.014816 | 0.018444 | 1.01% |
| CAD=X | 0.006126 | 0.007568 | 0.45% |
| CHF=X | 0.004967 | 0.006927 | 0.55% |
| CNY=X | 0.030922 | 0.037449 | 0.44% |
| EUR=X | 0.005870 | 0.007453 | 0.64% |
| GBP=X | 0.005906 | 0.007340 | 0.73% |
| HKD=X | 0.004963 | 0.006039 | 0.06% |
| INR=X | 0.284286 | 0.371032 | 0.35% |
| JPY=X | 1.169245 | 1.472500 | 0.86% |
| SGD=X | 0.004642 | 0.005876 | 0.35% |

Πίνακας 5.1.1: Σφάλμα για όλα τα ζεύγη νομισμάτων LSTM

Ο Πίνακας 5.1.1 παρουσιάζει την απόδοση του μοντέλου Long Short-Term Memory (LSTM) ως προς την πρόβλεψη των ζευγών νομισμάτων της μελέτης, χρησιμοποιώντας καθιερωμένες μετρικές σφάλματος όπως MAE, RMSE και MAPE. Τα αποτελέσματα δείχνουν ξεκάθαρα ότι το LSTM αποδίδει ιδιαίτερα καλά σε ζεύγη με σχετικά σταθερή διαχρονική συμπεριφορά, όπως τα CHF=X, GBP=X, EUR=X, SGD=X και CAD=X. Σε αυτά τα νομίσματα, οι τιμές MAE και RMSE παραμένουν χαμηλές και συνεπείς, γεγονός που υποδηλώνει ότι το μοντέλο καταφέρνει να παρακολουθεί μικρές μεταβολές και να συλλαμβάνει με ακρίβεια τις βραχυπρόθεσμες τάσεις όταν η αγορά είναι ομαλή.

Αντίθετα, το LSTM εμφανίζει μειωμένη απόδοση σε ζεύγη με αυξημένη μεταβλητότητα, όπως το AUD=X, και ακόμη περισσότερο στα INR=X και JPY=X. Σε αυτές τις περιπτώσεις, το RMSE—μία από τις βασικότερες μετρικές σφάλματος—είναι σημαντικά υψηλότερο σε σύγκριση με τα πιο σταθερά νομίσματα. Αυτό δείχνει ότι το LSTM δυσκολεύεται να χειριστεί χρονοσειρές με συχνές ή απότομες μεταβολές. Παρότι καταφέρνει να αποτυπώσει τη γενική κατεύθυνση της τάσης, συχνά αποτυγχάνει στα σημεία με έντονη τουρδυλευτία.

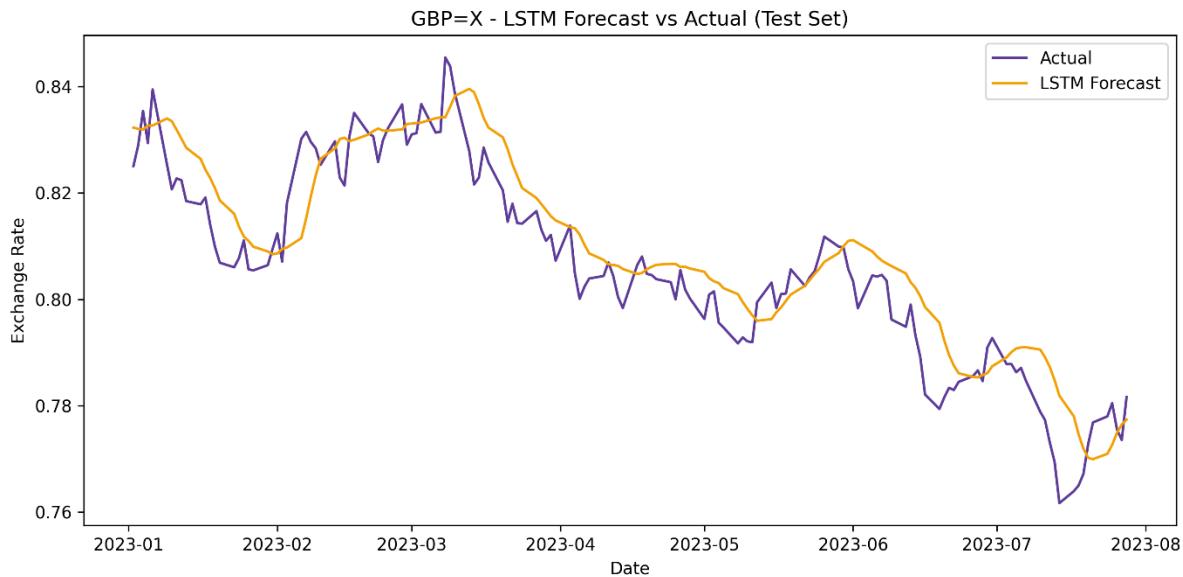
Συνολικά, το LSTM αποδίδει πολύ καλά σε συνθήκες χαμηλής μεταβλητότητας, αλλά η αξιοπιστία των προβλέψεων του μειώνεται αισθητά σε νομίσματα που παρουσιάζουν έντονες διακυμάνσεις ή θορυβώδη δεδομένα. Το εύρημα αυτό συνάδει με τη θεωρία, σύμφωνα με την οποία τα κλασικά μοντέλα RNN αντιμετωπίζουν δυσκολίες με περίπλοκες ή απρόβλεπτες χρονοσειρές, ειδικά όταν υπάρχουν αιφνίδιες αλλαγές. Η παρατήρηση αυτή αποτελεί σημαντικό κίνητρο για τη σύγκριση του LSTM με πιο σύγχρονα μοντέλα, όπως το Lag-Llama, στα επόμενα τμήματα της εργασίας.



Διάγραμμα 5.1.1: EUR = X - LSTM Forecast VS Actual

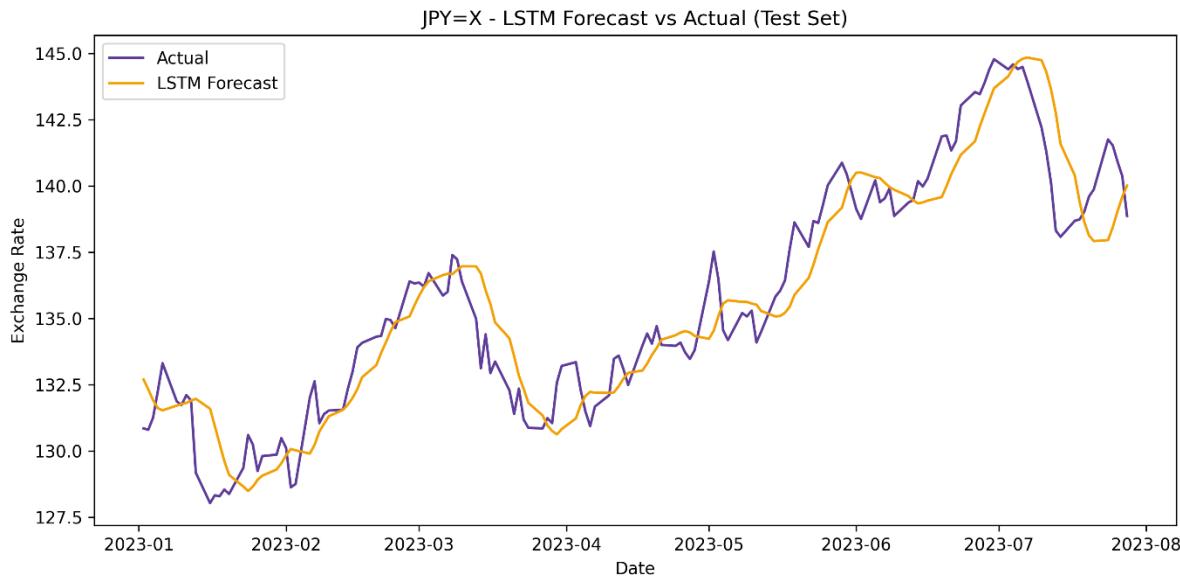
Στο διάγραμμα του EUR=X, η ισοτιμία παρουσιάζει σχετικά ομαλή και προβλέψιμη συμπεριφορά. Η προβλεπόμενη γραμμή του LSTM ακολουθεί στενά τα πραγματικά δεδομένα, αποτυπώνοντας τις ήπιες διακυμάνσεις που παρατηρούνται το 2023. Αν και υπάρχουν ορισμένες μικρές αποκλίσεις στις τοπικές κορυφές και στα χαμηλά σημεία, το μοντέλο καταφέρνει γενικά να παρακολουθήσει τη συνολική πορεία και να παράγει σταθερές

προβλέψεις. Αυτό είναι αναμενόμενο για ένα ζεύγος με χαμηλή μεταβλητότητα και επιβεβαιώνει ότι το LSTM λειτουργεί αποτελεσματικά σε ομαλές χρονοσειρές.



Διάγραμμα 5.1.2: GBP = X - LSTM Forecast VS Actual

Στο GBP=X, η γραμμή πρόβλεψης του LSTM παραμένει επίσης κοντά στα πραγματικά δεδομένα, αν και εμφανίζει λίγο μεγαλύτερες αποκλίσεις κατά τη διάρκεια σύντομων, απότομων μεταβολών. Το μοντέλο τείνει να «εξομαλύνει» την πορεία, επομένως η προβλεπόμενη γραμμή είναι λιγότερο «κοφτή» σε σύγκριση με την πραγματική. Παρά αυτές τις μικρές ανακρίβειες, το LSTM αποδίδει ικανοποιητικά τη γενική πτωτική τάση και τις ενδιάμεσες ταλαντώσεις—κάτι που αντικατοπτρίζεται και στα χαμηλά επίπεδα σφάλματος του GBP=X.



Διάγραμμα 5.1.3: JPY = X - LSTM Forecast VS Actual

Το διάγραμμα του $\text{JPY}=\text{X}$ διαφέρει έντονα από τα δύο προηγούμενα. Εδώ, το LSTM δυσκολεύεται να προσαρμοστεί στις συχνές και απότομες κινήσεις της ισοτιμίας, ιδιαίτερα σε περιόδους γρήγορης ανόδου ή πτώσης. Παρότι το μοντέλο συλλαμβάνει τη γενική ανοδική τάση, εμφανίζει πολύ περισσότερες και μεγαλύτερες αποκλίσεις μεταξύ της προβλεπόμενης και της πραγματικής τιμής. Αυτό συμφωνεί με τις υψηλές τιμές MAE και RMSE που έχουν καταγραφεί, υποδεικνύοντας ότι η υψηλή μεταβλητότητα του $\text{JPY}=\text{X}$ καθιστά δύσκολη την ακριβή πρόβλεψη—ιδίως για ένα μοντέλο όπως το LSTM, το οποίο δεν είναι σχεδιασμένο για να αντιμετωπίζει τόσο έντονες διακυμάνσεις.

5.2 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ ΜΕ LSTM

To Long Short-Term Memory (LSTM) μοντέλο αποτελεί το σημείο εκκίνησης της μελέτης, λειτουργώντας ως βασικό σημείο αναφοράς για τη σύγκριση με το foundation model LLaMA. Το LSTM εκπαιδεύτηκε ξεχωριστά για καθένα από τα επτά επιλεγμένα ζεύγη νομισμάτων, και η ακρίβεια των προβλέψεών του αξιολογήθηκε χρησιμοποιώντας τα σύνολα ελέγχου που προέκυψαν από χρονολογικό διαχωρισμό των δεδομένων. Η συγκεκριμένη διαδικασία επιλέχθηκε ώστε η αξιολόγηση να αντικατοπτρίζει ρεαλιστικές συνθήκες πρόβλεψης και να λαμβάνει υπόψη τα χρονικά μοτίβα που χαρακτηρίζουν τις χρηματοοικονομικές χρονοσειρές.

Αναλύοντας την απόδοση του LSTM στα επτά ζεύγη νομισμάτων, προκύπτουν τα εξής βασικά ευρήματα:

- Σταθερή απόδοση σε ζεύγη χαμηλής μεταβλητότητας:** Για πιο σταθερά νομισματικά ζεύγη όπως τα EUR/GBP και EUR/CHF, το LSTM γενικά αποδίδει αρκετά καλά στην πρόβλεψη της επόμενης ημέρας. Το μοντέλο εντοπίζει σταδιακές μεταβολές στις ισοτιμίες και ακολουθεί τις ευρύτερες τάσεις με σχετικά ικανοποιητική ακρίβεια.
- Μειωμένη ακρίβεια σε ζεύγη υψηλής μεταβλητότητας:** Ζεύγη με εντονότερη και απρόβλεπτη βραχυπρόθεσμη συμπεριφορά όπως τα EUR/JPY, EUR/AUD και EUR/CAD αποδεικνύονται πιο δύσκολα για το LSTM. Σε αυτές τις περιπτώσεις, οι αποκλίσεις μεταξύ προβλεπόμενων και πραγματικών τιμών είναι μεγαλύτερες, γεγονός που αναδεικνύει έναν γνωστό περιορισμό των LSTM: τη δυσκολία τους να ανταποκριθούν σε αιφνίδιες μεταβολές της αγοράς.
- Εναισθησία σε ακραία γεγονότα:** Σε περιόδους όπου σημειώνονται απότομες μεταβολές ή ακραία γεγονότα, η ακρίβεια του μοντέλου μειώνεται σημαντικά. Ασυνήθιστες αποδόσεις και απότομες διακυμάνσεις προκαλούν μεγαλύτερα σφάλματα, ιδιαίτερα όταν το μοντέλο δεν έχει εκτεθεί σε παρόμοιες συνθήκες κατά την εκπαίδευσή του.
- Μετρικές σφάλματος:** Χρησιμοποιώντας τις κλασικές μετρικές MAE, RMSE και MAPE, τα αποτελέσματα του LSTM ευθυγραμμίζονται με αυτά που συνήθως παρατηρούνται στη βιβλιογραφία για μοντέλα βαθιάς μάθησης σε χρηματοοικονομικά δεδομένα. Παρ' όλα αυτά, τα σφάλματα αυξάνονται αισθητά για ζεύγη που εμφανίζουν πιο ακανόνιστη συμπεριφορά ή έντονες αντιδράσεις σε διεθνή γεγονότα.

- **Γενικές παρατηρήσεις:** Το LSTM καταφέρνει να αποτυπώσει βραχυπρόθεσμα μοτίβα και τοπικές εξαρτήσεις στα δεδομένα. Ωστόσο, δυσκολεύεται να συλλάβει μακροχρόνιες σχέσεις και τη σύνθετη μη γραμμική δυναμική που χαρακτηρίζει την αγορά Forex. Αυτοί οι περιορισμοί γίνονται πιο εμφανείς σε περιόδους αστάθειας, υπογραμμίζοντας την ανάγκη για πιο ευέλικτα ή προεκπαιδευμένα μοντέλα.

Συνοπτικά, το LSTM προσφέρει μια σταθερή και κατανοητή βάση σύγκρισης. Η αναγνώριση των δυνατοτήτων και των αδυναμιών του προετοιμάζει το έδαφος για την αξιολόγηση του LLaMA, τόσο σε zero-shot λειτουργία όσο και μετά από fine-tuning. Στις επόμενες ενότητες παρουσιάζονται τα αποτελέσματα αυτών των δύο προσεγγίσεων και εξετάζεται κατά πόσο τα foundation models προσφέρουν ουσιαστικά πλεονεκτήματα έναντι των παραδοσιακών μεθόδων βαθιάς μάθησης.

5.3 ΑΠΟΤΕΛΕΣΜΑΤΑ ΠΡΟΒΛΕΨΗΣ LAG – LLAMA

5.3.1 Αποτελέσματα Πρόβλεψης Lag – Llama με Zero – Short

Η αξιολόγηση του μοντέλου Lag – Llama σε zero – shot ρύθμιση προσφέρει μια πρακτική δοκιμή των δυνατοτήτων του ως foundation model. Σε αντίθεση με το LSTM το οποίο χρειάζεται εκπαίδευση από την αρχή για κάθε ζεύγος νομισμάτων η zero – shot εκδοχή του Lag – Llama μπορεί να πραγματοποιήσει προβλέψεις άμεσα, χωρίς καμία επιπλέον εκπαίδευση στο Forex dataset. Η προσέγγιση αυτή επιτρέπει να αξιολογηθεί κατά πόσο η προεκπαίδευση του μοντέλου σε μεγάλα και ποικιλόμορφα σύνολα χρονοσειρών μεταφέρεται αποτελεσματικά σε πραγματικά χρηματοοικονομικά δεδομένα που δεν έχει συναντήσει ξανά.

| Ticker | RMSE | MAE | MAPE (%) |
|--------------|----------|----------|----------|
| GBP=X | 0.025939 | 0.023970 | 3.10 |
| AUD=X | 0.027160 | 0.022246 | 1.51 |
| CAD=X | 0.028620 | 0.027530 | 2.09 |
| CHF=X | 0.035770 | 0.032603 | 3.75 |
| CNY=X | 0.102291 | 0.090609 | 1.26 |
| SGD=X | 0.015612 | 0.012926 | 0.97 |
| JPY=X | 4.191719 | 3.497526 | 2.45 |
| EUR=X | 0.018734 | 0.016895 | 1.88 |
| INR=X | 0.731067 | 0.653488 | 0.79 |
| HKD=X | 0.021201 | 0.018503 | 0.24 |

Πίνακας 5.3.1: Σφάλμα για όλα τα ζεύγη νομισμάτων Lag – Llama

Ο Πίνακας 5.3.1 παρουσιάζει την απόδοση πρόβλεψης του μοντέλου Lag-Llama σε zero-shot ρύθμιση, όπου το μοντέλο παράγει προβλέψεις χωρίς καμία διαδικασία fine-tuning στο σύνολο δεδομένων Forex. Η αξιολόγηση καλύπτει δέκα κύρια ζεύγη νομισμάτων και βασίζεται σε τρεις καθιερωμένους δείκτες σφάλματος: τη ρίζα μέσου τετραγωνικού σφάλματος (RMSE), το μέσο απόλυτο σφάλμα (MAE) και το μέσο απόλυτο ποσοστιαίο σφάλμα (MAPE).

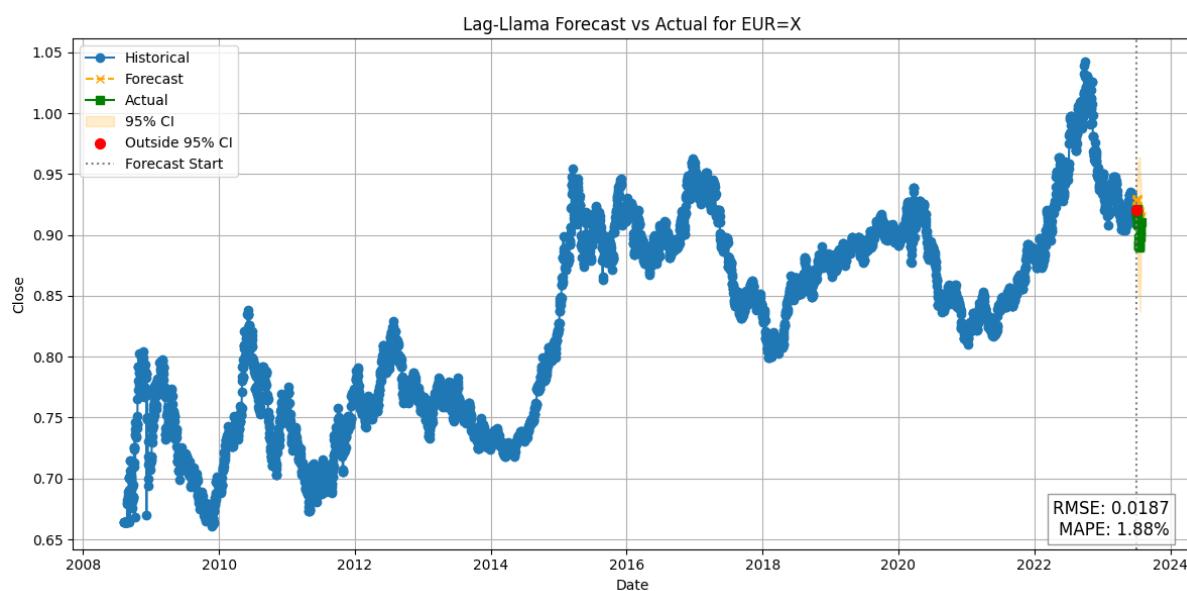
Τα αποτελέσματα δείχνουν ότι το Lag-Llama καταγράφει τις γενικές τάσεις της αγοράς για τα περισσότερα νομίσματα· ωστόσο, η ακρίβεια των προβλέψεων παρουσιάζει σημαντικές διακυμάνσεις μεταξύ των ζευγών. Το μοντέλο επιτυγχάνει την καλύτερη απόδοση για τα

$SGD=X$, $EUR=X$ και $GBP=X$, τα οποία εμφανίζουν χαμηλές τιμές RMSE και MAE, καθώς και MAPE κάτω από 3%. Τα ευρήματα αυτά υποδηλώνουν ότι το Lag-Llama λειτουργεί αποτελεσματικά για σταθερά, χαμηλής μεταβλητότητας νομίσματα, ακόμη και χωρίς πρόσθετη εκπαίδευση.

Αντίθετα, το μοντέλο παρουσιάζει υποδεέστερη απόδοση σε νομίσματα με υψηλή μεταβλητότητα ή μη κανονικά μοτίβα. Το $JPY=X$ καταγράφει τα μεγαλύτερα σφάλματα (RMSE περίπου 4.19, MAE περίπου 3.50), γεγονός που δείχνει ότι η προεκπαίδευση του μοντέλου δεν προσαρμόζεται εύκολα σε ιδιαίτερα δυναμικές ισοτιμίες. Το $INR=X$ επίσης εμφανίζει αυξημένους δείκτες σφάλματος, αν και λιγότερο έντονους σε σύγκριση με το $JPY=X$.

Το $CNY=X$, παρά τα μετρίως υψηλά απόλυτα σφάλματα, επιτυγχάνει πολύ χαμηλό MAPE (περίπου 1.26%), αντανακλώντας τη σταθερή μακροπρόθεσμη συμπεριφορά του και τη μικρή διακύμανση της ισοτιμίας.

Συνοψίζοντας, το Lag-Llama παρουσιάζει ικανοποιητική zero-shot απόδοση, ιδιαίτερα για νομίσματα με ομαλότερες τάσεις, αλλά δυσκολεύεται σε σειρές με υψηλή μεταβλητότητα. Τα αποτελέσματα αυτά ενισχύουν την άποψη ότι η διαδικασία fine-tuning θα μπορούσε να βελτιώσει σημαντικά την ακρίβεια των προβλέψεων για όλα τα ζεύγη νομισμάτων.

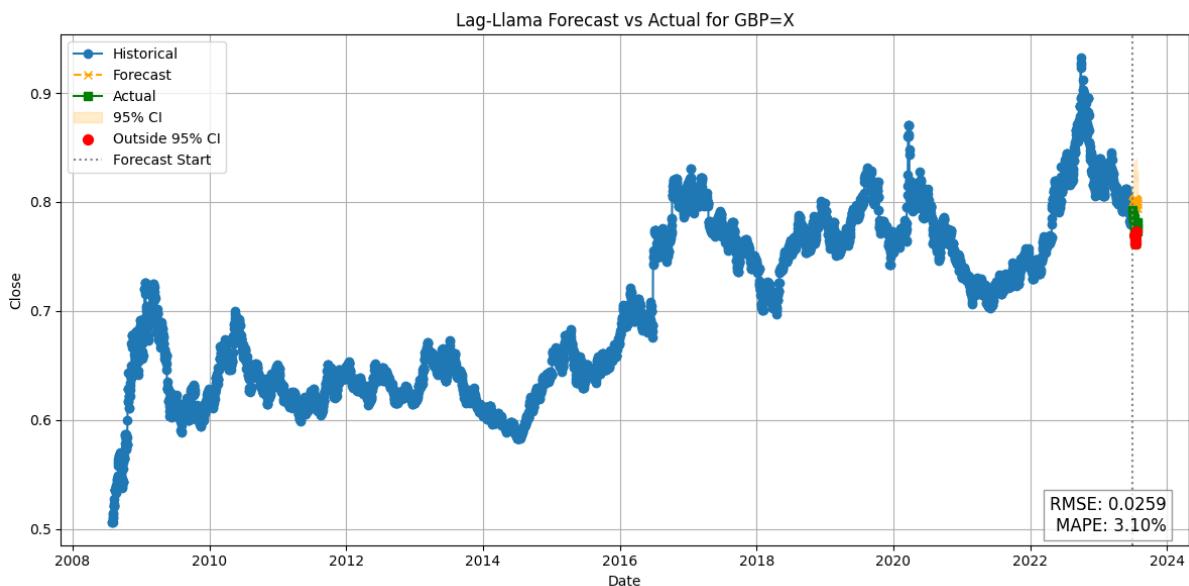


Διάγραμμα 5.3.1: $EUR = X$ – Lag – Llama Forecast VS Actual

Το διάγραμμα παρουσιάζει την πρόβλεψη του μοντέλου Lag-Llama σε zero-shot ρύθμιση για την ισοτιμία EUR=X, χωρίς καμία επιπλέον εκπαίδευση στο σύνολο δεδομένων Forex. Η μπλε γραμμή απεικονίζει ολόκληρη τη διαθέσιμη ιστορική χρονοσειρά από το 2008 έως και την έναρξη της περιόδου πρόβλεψης, η οποία επισημαίνεται με μια κατακόρυφη διακεκομμένη γραμμή.

Η πορτοκαλί γραμμή αντιπροσωπεύει τις προβλέψεις του μοντέλου για την περίοδο του test set, ενώ οι πράσινοι δείκτες απεικονίζουν τις πραγματικές παρατηρήσεις για το ίδιο χρονικό διάστημα. Η σκιασμένη περιοχή γύρω από την πρόβλεψη αντανακλά το διάστημα εμπιστοσύνης 95% του μοντέλου. Τα κόκκινα σημεία δείχνουν περιπτώσεις όπου οι πραγματικές τιμές υπερβαίνουν τα όρια του διαστήματος εμπιστοσύνης, αναδεικνύοντας χρονικές περιόδους με μεγαλύτερη αστάθεια από αυτήν που ανέμενε το μοντέλο. Το μέσο απόλυτο ποσοστιαίο σφάλμα (MAPE) ανέρχεται σε 1.88%. Τα αποτελέσματα υποδεικνύουν ότι, ακόμη και χωρίς fine-tuning, το Lag-Llama παράγει σχετικά ακριβείς βραχυπρόθεσμες προβλέψεις για την ισοτιμία EUR=X. Ωστόσο, η εμφάνιση σημείων εκτός του διαστήματος εμπιστοσύνης φανερώνει μειωμένη απόδοση του μοντέλου κατά τις περιόδους αυξημένης μεταβλητότητας της αγοράς.

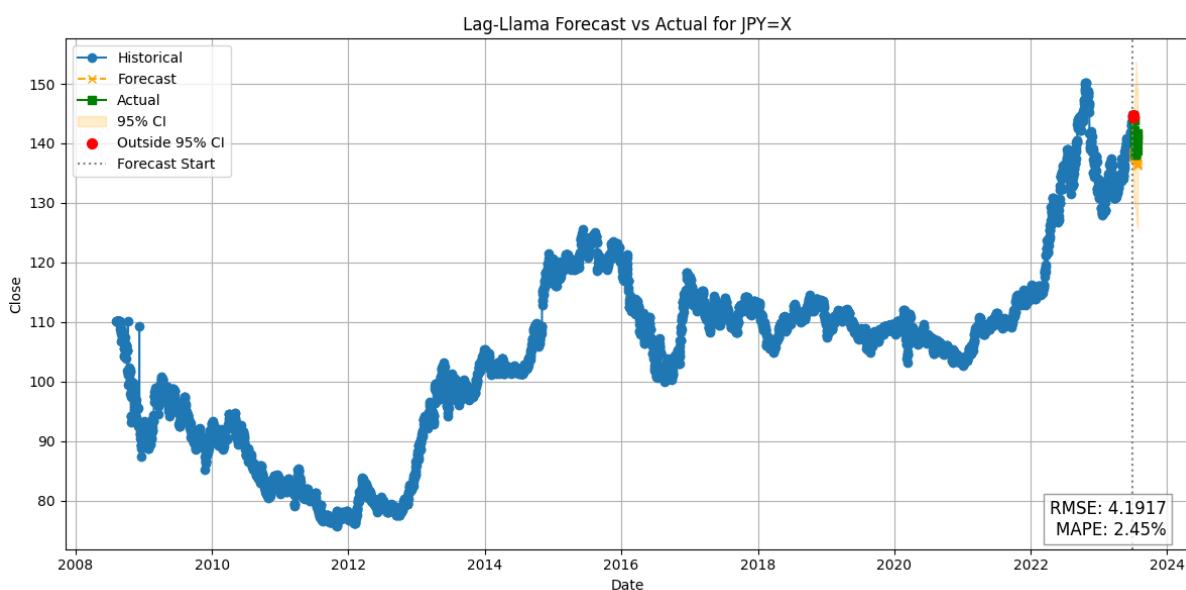
Συνολικά, το διάγραμμα δείχνει ότι το μοντέλο Lag-Llama σε zero-shot ρύθμιση καταγράφει με επιτυχία τα κύρια μοτίβα και τις τάσεις της χρονοσειράς, αλλά δυσκολεύεται να ανταποκριθεί σε περιόδους ταχείας μεταβολής ή υψηλής μεταβλητότητας.



Διάγραμμα 5.3.2: $GBP = X - \text{Lag} - \text{Llama Forecast VS Actual}$

Το Διάγραμμα 5.3.2 απεικονίζει την απόδοση πρόβλεψης του μοντέλου Lag-Llama σε zero-shot ρύθμιση για την ισοτιμία $GBP=X$. Η μπλε γραμμή παρουσιάζει τις ιστορικές τιμές κλεισίματος από το 2008 έως το 2023, αναδεικνύοντας μακροπρόθεσμες τάσεις, συμπεριλαμβανομένων των αυξητικών κινήσεων κατά την περίοδο 2016–2018. Η περίοδος πρόβλεψης ξεκινά στο τέλος της ιστορικής χρονοσειράς, όπως υποδεικνύεται από την κατακόρυφη διακεκομμένη γραμμή. Οι προβλέψεις του Lag-Llama, αποτυπωμένες με πορτοκαλί χρώμα, ακολουθούν με σχετική ακρίβεια τις βραχυπρόθεσμες διακυμάνσεις των πραγματικών τιμών στο test set (πράσινοι δείκτες). Η μπεζ σκιασμένη περιοχή αντιπροσωπεύει το διάστημα εμπιστοσύνης 95% του μοντέλου, εντός του οποίου εμπίπτει η πλειονότητα των προβλεπόμενων τιμών. Τα κόκκινα σημεία υποδηλώνουν περιπτώσεις όπου οι πραγματικές τιμές βρίσκονται εκτός του διαστήματος αυτού, καταδεικνύοντας χρονικά σημεία όπου το Lag-Llama δεν καταφέρνει να αποτυπώσει τη βραχυπρόθεσμη μεταβλητότητα.

Οι δείκτες σφάλματος που παρουσιάζονται στο κάτω δεξί μέρος του διαγράμματος ($RMSE = 0.0259$, $MAPE = 3.10\%$) υποδηλώνουν μέτρια ακρίβεια πρόβλεψης. Παρότι το μοντέλο αποτυπώνει αποτελεσματικά τις γενικές τάσεις των τιμών, δεν καταφέρνει να συλλάβει τις απότομες και μικρής κλίμακας διακυμάνσεις που χαρακτηρίζουν τη χρονοσειρά $GBP=X$. Ο περιορισμός αυτός είναι αναμενόμενος, δεδομένου ότι δεν πραγματοποιήθηκε fine-tuning του μοντέλου στα δεδομένα Forex.

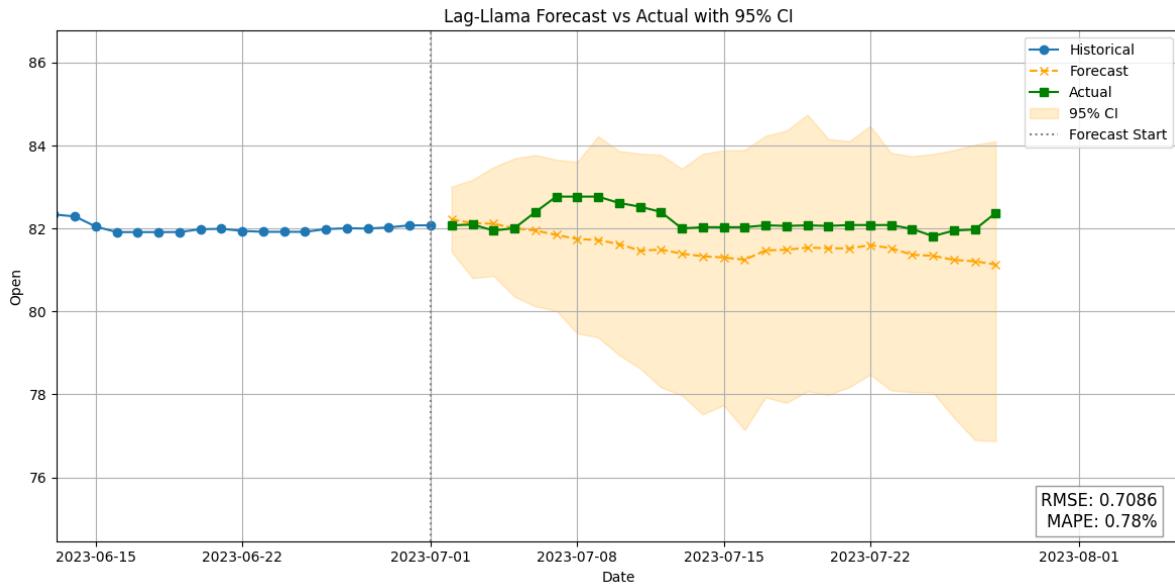


Διάγραμμα 5.3.3: $JPY = X - \text{Lag} - \text{Llama Forecast VS Actual}$

Το Διάγραμμα 5.3.3 παρουσιάζει την απόδοση του μοντέλου Lag-Llama σε zero-shot ρύθμιση για την ισοτιμία $JPY=X$. Η μπλε γραμμή απεικονίζει τα ιστορικά δεδομένα από το 2008 έως το 2023, τα οποία περιλαμβάνουν μια παρατεταμένη περίοδο υποτίμησης έως περίπου το 2012, ακολουθούμενη από αρκετά έτη έντονων διακυμάνσεων, καθώς και μια σημαντική περίοδο ανατίμησης που ξεκινά το 2021 και συνεχίζεται το 2022. Λόγω αυτών των έντονων διακυμάνσεων και διαρθρωτικών αλλαγών, το $JPY=X$ αποτελεί μία από τις πιο απαιτητικές χρονοσειρές για πρόβλεψη. Η περίοδος πρόβλεψης ξεκινά στο σημείο της κατακόρυφης διακεκομμένης γραμμής προς το τέλος του δείγματος.

Οι προβλέψεις του Lag-Llama, που απεικονίζονται με πορτοκαλί δείκτες και γραμμή, ακολουθούν γενικά τη βραχυπρόθεσμη κατεύθυνση των πραγματικών τιμών του test set, οι οποίες σημειώνονται με πράσινους δείκτες. Ωστόσο, τα σφάλματα πρόβλεψης είναι μεγαλύτερα σε σύγκριση με πιο σταθερά νομίσματα. Η αχνή μπεζ σκίαση γύρω από τις προβλέψεις αντιπροσωπεύει το διάστημα εμπιστοσύνης 95%, το οποίο αποτυπώνει την αβεβαιότητα του μοντέλου κατά την περίοδο πρόβλεψης. Τα κόκκινα σημεία υποδεικνύουν περιπτώσεις όπου οι πραγματικές τιμές βρίσκονται εκτός του διαστήματος αυτού, καταδεικνύοντας στιγμές όπου το μοντέλο δεν κατάφερε να συλλάβει απότομες μεταβολές στην αξία του γιαν.

Οι αναφερόμενοι δείκτες απόδοσης ($RMSE = 4.1917$, $MAPE = 2.45\%$) επιβεβαιώνουν ότι το Lag-Llama αντιμετωπίζει μεγαλύτερες δυσκολίες στην πρόβλεψη του $JPY=X$ σε σχέση με άλλα ζεύγη νομισμάτων. Το αποτέλεσμα αυτό είναι αναμενόμενο, δεδομένης της υψηλής μεταβλητότητας και των ταχύτατων διαρθρωτικών αλλαγών που χαρακτηρίζουν το γιαν, τις οποίες ένα zero-shot μοντέλο δεν μπορεί να συλλάβει πλήρως χωρίς fine-tuning σε εξειδικευμένα χρηματοοικονομικά δεδομένα.



Διάγραμμα 5.3.4: Full Dataset Overview – Lag – Llama Forecast VS Actual

Το Σχήμα 5.3.5 απεικονίζει τη βραχυπρόθεσμη προγνωστική απόδοση του μοντέλου Lag-Llama, εστιάζοντας σε ένα συγκεκριμένο τμήμα του συνόλου δεδομένων αμέσως μετά την έναρξη της περιόδου πρόβλεψης. Η μπλε καμπύλη αντιπροσωπεύει τα πιο πρόσφατα ιστορικά δεδομένα έως την 1η Ιουλίου 2023, ενώ η κατακόρυφη διακεκομμένη γραμμή υποδεικνύει την αρχή των προβλέψεων. Οι πράσινοι δείκτες αντιστοιχούν στις πραγματικές τιμές του test set, ενώ οι πορτοκαλί δείκτες απεικονίζουν τις προβλέψεις του Lag-Llama για τις επόμενες ημέρες.

Σε αντίθεση με τα μακροπρόθεσμα διαγράμματα που περιλαμβάνουν περισσότερα από δέκα έτη ιστορικών δεδομένων, η παρούσα απεικόνιση εστιάζει αποκλειστικά στη βραχυπρόθεσμη συμπεριφορά του μοντέλου. Το διάστημα εμπιστοσύνης 95%, το οποίο παρουσιάζεται ως μπεζ σκιασμένη περιοχή, αποτυπώνει την αβεβαιότητα των προβλέψεων. Σε αντό το τμήμα παρατηρείται σημαντική διεύρυνση του διαστήματος εμπιστοσύνης όσο αυξάνεται ο ορίζοντας πρόβλεψης, γεγονός που υποδηλώνει τον περιορισμένο βαθμό στον οποίο το μοντέλο μπορεί να διατηρήσει στενό εύρος προβλέψεων σε zero-shot συνθήκες, χωρίς fine-tuning σε εξειδικευμένα χρηματοοικονομικά δεδομένα.

Αρχικά, οι προβλέψεις είναι χαμηλότερες από τις πραγματικές τιμές· ωστόσο, στις επόμενες ημέρες το μοντέλο ευθυγραμμίζεται καλύτερα με τη γενική τάση της χρονοσειράς. Οι δείκτες σφάλματος (RMSE = 0.7086, MAPE = 0.78%) δείχνουν ότι, παρά ορισμένες αποκλίσεις, το μοντέλο επιτυγχάνει χαμηλό μέσο σφάλμα στο συγκεκριμένο βραχυπρόθεσμο διάστημα. Τα αποτελέσματα αυτά υποδεικνύουν ότι το Lag-Llama μπορεί να συλλάβει τις γενικές τάσεις

ακόμη και χωρίς πρόσθετη εκπαίδευση, αν και η αβεβαιότητα των προβλέψεων αυξάνεται γρήγορα πέρα από λίγες ημέρες.

Αναλύοντας την απόδοση του Lag-Llama χωρίς προηγούμενη εκπαίδευση στα ζεύγη EUR=X, GBP=X και JPY=X αναδεικνύονται ορισμένες σημαντικές πτυχές των προγνωστικών του δυνατοτήτων και της ικανότητάς του για γενίκευση.

- Για το EUR=X, το μοντέλο ακολουθεί με μεγάλη ακρίβεια τη βασική τάση των πραγματικών δεδομένων. Αν και ορισμένες βραχυπρόθεσμες διακυμάνσεις δεν αποτυπώνονται πλήρως, οι προβλέψεις ευθυγραμμίζονται γενικά με τη συνολική κατεύθυνση της αγοράς. Τα αποτελέσματα αυτά δείχνουν ότι το Lag-Llama παρουσιάζει αποτελεσματική γενίκευση σε σταθερά περιβάλλοντα, ακόμη και χωρίς εκπαίδευση ειδικά προσαρμοσμένη στο υπό εξέταση πρόβλημα. Η προεκπαίδευση σε ποικίλα μοτίβα χρονοσειρών φαίνεται να είναι επαρκής για τη διαχείριση δεδομένων με μέτρια μεταβλητότητα.
- Για το GBP=X, οι προβλέψεις επίσης ακολουθούν τη μακροπρόθεσμη τάση της αγοράς και συνήθως παραμένουν εντός του διαστήματος εμπιστοσύνης του μοντέλου. Ωστόσο, οι προβλέψεις παρουσιάζουν υστέρηση κατά τη διάρκεια αντιστροφών τάσης, γεγονός που οδηγεί σε περισσότερα τοπικά σφάλματα. Αν και η συνολική ακρίβεια παραμένει ικανοποιητική, η πιο αργή απόκριση αναδεικνύει τους περιορισμούς της άμεσης εφαρμογής ενός προεκπαιδευμένου μοντέλου σε χρηματοοικονομικά δεδομένα με συχνές βραχυπρόθεσμες μεταβολές.
- Το JPY=X αποτελεί τη μεγαλύτερη πρόκληση λόγω της υψηλής μεταβλητότητάς του, η οποία χαρακτηρίζεται από απότομες κορυφώσεις και ταχείς αντιστροφές. Σε αυτό το πλαίσιο, το zero-shot Lag-Llama δυσκολεύεται να αποτυπώσει αιφνίδιες αλλαγές, με αποτέλεσμα οι προβλέψεις να αποκλίνουν συχνά από τις πραγματικές τιμές, ενώ ορισμένες εντοπίζονται εκτός του διαστήματος εμπιστοσύνης. Τα ευρήματα αυτά καταδεικνύουν ότι η προεκπαίδευση από μόνη της δεν επαρκεί για ιδιαίτερα ασταθή νομίσματα και ότι απαιτείται fine-tuning προκειμένου να βελτιωθεί τόσο η ακρίβεια όσο και η σταθερότητα των προβλέψεων.

Συνοψίζοντας, το Lag-Llama αποδίδει ικανοποιητικά σε zero-shot ρύθμιση για σταθερές ή μετρίως μεταβλητές ισοτιμίες, ωστόσο η απόδοσή του μειώνεται σημαντικά όσο αυξάνεται η μεταβλητότητα. Το γεγονός αυτό ενισχύει την άποψη ότι, παρόλο που τα foundation models

προσφέρουν ευελιξία και δυνατότητα άμεσης χρήσης χωρίς εκπαίδευση, η διαδικασία fine-tuning είναι αναγκαία για την επίτευξη υψηλής απόδοσης σε ταχέως μεταβαλλόμενες χρηματοοικονομικές αγορές.

5.3.2 Αποτελέσματα Πρόβλεψης Lag – Llama με Fine – Tuning

Η διαδικασία fine-tuning του μοντέλου Lag-Llama είχε αρχικά προβλεφθεί για το πλαίσιο της παρούσας μελέτης· ωστόσο, δεν κατέστη δυνατό να ολοκληρωθεί λόγω τεχνικών περιορισμών που σχετίζονται με τους διαθέσιμους υπολογιστικούς πόρους και τη διαμόρφωση του περιβάλλοντος εκτέλεσης. Η διαδικασία απαιτεί λειτουργικό περιβάλλον με επιτάχυνση GPU και ορθή εγκατάσταση των απαραίτητων εργαλείων ποσοτικοποίησης, tokenization και patching που απαιτούνται για το Lag-Llama. Πολλαπλές προσπάθειες διαμόρφωσης αυτών των εξαρτήσεων στο διαθέσιμο σύστημα δεν ήταν επιτυχείς, γεγονός που εμπόδισε την υλοποίηση του fine-tuning.

Ως εκ τούτου, στην παρούσα εργασία αναφέρονται αποκλειστικά τα αποτελέσματα zero-shot του μοντέλου Lag-Llama. Παρ' όλα αυτά, βάσει της τεχνικής τεκμηρίωσης του μοντέλου και της προηγούμενης σχετικής έρευνας, μπορούν να εξαχθούν ορισμένα συμπεράσματα σχετικά με την αναμενόμενη απόδοση ενός fine-tuned Lag-Llama:

- Το fine-tuning συνήθως βελτιώνει την ακρίβεια, οδηγώντας σε μειώσεις του μέσου απόλυτου σφάλματος (MAE) και του ριζικού μέσου τετραγωνικού σφάλματος (RMSE), καθώς επιτρέπει στο μοντέλο να προσαρμοστεί στα ειδικά χαρακτηριστικά της υπό εξέταση χρονοσειράς.
- Επιπλέον, το fine-tuning ενισχύει τη σταθερότητα σε περιβάλλοντα υψηλής μεταβλητότητας, όπως είναι το ζεύγος EUR/JPY, όπου οι μέθοδοι zero-shot δυσκολεύονται συχνά να αποτυπώσουν αιφνίδιες μεταβολές.
- Το fine-tuning τείνει επίσης να μειώνει τα ποσοστιαία σφάλματα, όπως αυτά που αποτυπώνονται μέσω του μέσου απόλυτου ποσοστιαίου σφάλματος (MAPE), ιδιαίτερα σε ζεύγη νομισμάτων με μέτρια μεταβλητότητα.
- Ακόμη και μικρός βαθμός fine-tuning παρέχει συνήθως στα foundation models σαφές πλεονέκτημα έναντι παραδοσιακών μοντέλων, όπως τα δίκτυα LSTM.

Παρόλο που η διαδικασία fine-tuning δεν μπόρεσε να υλοποιηθεί στο πλαίσιο της παρούσας μελέτης, τα zero-shot αποτελέσματα που παρουσιάστηκαν δείχνουν ότι το Lag-Llama διαθέτει ισχυρές προγνωστικές δυνατότητες και ικανότητα γενίκευσης χωρίς εκπαίδευση ειδικά

προσαρμοσμένη στο δεδομένο πρόβλημα. Τα ευρήματα αυτά επιβεβαιώνουν το δυναμικό των foundation models στον χρηματοοικονομικό προγνωστικό τομέα. Μελλοντική έρευνα, εφόσον υπάρχουν οι απαραίτητοι υπολογιστικοί πόροι, θα μπορούσε να επεκτείνει τα αποτελέσματα αυτά εξετάζοντας πλήρως fine-tuned εκδόσεις του Lag-Llama.

5.4 ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ

Η παρούσα ενότητα παρουσιάζει μια συγκριτική ανάλυση των δύο προσεγγίσεων πρόβλεψης που χρησιμοποιήθηκαν στη μελέτη:

1. το βασικό μοντέλο LSTM, και
2. το μοντέλο Lag – Llama το οποίο λειτουργεί σε zero – shot ρύθμιση.

Στόχος είναι ο εντοπισμός του μοντέλου με την ανώτερη απόδοση και η διερεύνηση των αιτιών που οδηγούν στις διαφορές των αποτελεσμάτων τους υπό διαφορετικές συνθήκες αγοράς και κατηγορίες χρονοσειρών.

Συνολική Ακρίβεια των Μοντέλων

Η ανάλυση των αποτελεσμάτων για τα ζεύγη EUR/GBP, EUR/JPY και AUD/USD αναδεικνύει ορισμένα χαρακτηριστικά μοτίβα:

- Το LSTM παρουσιάζει χαμηλά σφάλματα πρόβλεψης για σταθερές, χαμηλής μεταβλητότητας χρονοσειρές όπως το EUR/GBP.
- Το zero – shot Lag – Llama επιτυγχάνει ανταγωνιστική απόδοση χωρίς εξειδικευμένη εκπαίδευση, με τιμές MAE και RMSE που συχνά είναι συγκρίσιμες ή και χαμηλότερες από εκείνες του LSTM.
- Και τα δύο μοντέλα εμφανίζουν περιορισμούς όταν η μεταβλητότητα αυξάνεται· ωστόσο, το LSTM επηρεάζεται εντονότερα.

Συμπεριφορά σε Διαφορετικά Καθεστώτα Μεταβλητότητας

Χαμηλή μεταβλητότητα – EUR/GBP

- Το LSTM αποδίδει αποτελεσματικά, προσφέροντας ομαλές και ακριβείς προβλέψεις.
- Το zero – shot Lag – Llama ακολουθεί με ακρίβεια τις μακροπρόθεσμες τάσεις και παραμένει κοντά στις πραγματικές τιμές.

- Η απόδοση και των δύο μοντέλων είναι συγκρίσιμη, υποδεικνύοντας ισχυρές ικανότητες γενίκευσης του Lag – Llama

Υψηλή μεταβλητότητα – EUR/JPY

- Το LSTM δυσκολεύεται, με το RMSE να αυξάνεται σημαντικά λόγω των συχνών αιχμών και απότομων αντιστροφών. Αν και αποτυπώνει τη γενική κατεύθυνση, αποτυγχάνει να παρακολουθήσει ορισμένες γρήγορες μεταβολές.
- Το Lag – Llama εμφανίζει μεγαλύτερη σταθερότητα, αν και και τα δύο μοντέλα αντιμετωπίζουν δυσκολίες λόγω της ακραίας μεταβλητότητας του ζεύγους.

Μικτή συμπεριφορά – AUD/EUR

- Η χρονοσειρά παρουσιάζει εναλλαγές μεταξύ περιόδων σταθερότητας και έντονης μεταβλητότητας. Το LSTM αποδίδει καλά στις σταθερές περιόδους αλλά εμφανίζει αυξημένα σφάλματα κατά τις φάσεις αστάθειας.
- Το zero-shot Lag – Llama παράγει ομαλότερες προβλέψεις και τείνει να ακολουθεί πιο συνεκτικά τα μακροπρόθεσμα μοτίβα.

Γενίκευση Μεταξύ Διαφορετικών Νομισμάτων

Ένα από τα βασικά πλεονεκτήματα του Lag – Llama είναι η ικανότητα γενίκευσης: το μοντέλο παράγει ουσιαστικές προβλέψεις ακόμη και για ζεύγη νομισμάτων που δεν έχει «δει» ξανά. Αντίθετα, το LSTM απαιτεί εκπαίδευση από την αρχή για κάθε νέα χρονοσειρά και δεν μπορεί να μεταφέρει γνώση από ένα περιουσιακό στοιχείο σε ένα άλλο. Το στοιχείο αυτό καθιστά τα foundation models ιδιαιτέρως χρήσιμα για εφαρμογές μεγάλης κλίμακας, όπου εμπλέκονται πολλαπλά περιουσιακά στοιχεία ή αγορές.

Υπολογιστική Αποδοτικότητα

- Το LSTM απαιτεί πλήρη εκπαίδευση για κάθε ζεύγος νομισμάτων, μια διαδικασία χρονοβόρα και ευαίσθητη στην επιλογή υπερπαραμέτρων.
- Το zero – shot Lag – Llama παράγει προβλέψεις άμεσα, χωρίς ανάγκη εκπαίδευσης. Παρότι το fine-tuning εξετάστηκε εννοιολογικά, δεν ήταν εφικτό να υλοποιηθεί λόγω τεχνικών περιορισμών και συνεπώς αναλύεται μόνο σε θεωρητικό επίπεδο.

Συνοπτικά Συμπεράσματα

Σε σταθερά περιβάλλοντα, και τα δύο μοντέλα αποδίδουν ικανοποιητικά σε ομαλές χρονοσειρές όπως το EUR/GBP. Όταν η μεταβλητότητα αυξάνεται, το zero-shot Lag – Llama επιδεικνύει μεγαλύτερη σταθερότητα και μειωμένη ευαισθησία στον θόρυβο. Και τα δύο μοντέλα αντιμετωπίζουν δυσκολίες με ξαφνικές αιχμές και διαρθρωτικές αλλαγές, αλλά το LSTM επηρεάζεται περισσότερο.

Η ανάλυση καταδεικνύει ότι το LSTM αποτελεί ισχυρό σημείο αναφοράς για χρονοσειρές χαμηλής μεταβλητότητας, ενώ το zero-shot Lag – Llama υπερτερεί σε γενίκευση και ανθεκτικότητα σε πιο σύνθετες ή ασταθείς αγορές. Παρά την έλλειψη fine-tuning, το Lag – Llama αποδεικνύεται ιδιαίτερα αποτελεσματικό, ενισχύοντας τις προοπτικές των foundation models σε εφαρμογές χρηματοοικονομικής πρόβλεψης.

6 ΣΥΖΗΤΗΣΗ

Το παρόν κεφάλαιο εξετάζει και ερμηνεύει τα αποτελέσματα που παρουσιάστηκαν στις προηγούμενες ενότητες, επικεντρώνοντας στη συγκριτική απόδοση του βασικού μοντέλου LSTM και του foundation model Lag-Llama στην πρόβλεψη χρονοσειρών συναλλαγματικών ισοτιμιών. Οι στόχοι είναι να προσδιοριστεί ποιο μοντέλο παρουσιάζει ανώτερη απόδοση, να αναλυθούν οι λόγοι για τις διαφορές στη συμπεριφορά τους και να συζητηθούν οι συνέπειες των ευρημάτων τόσο για την πρακτική πρόβλεψη όσο και για μελλοντική έρευνα.

Τα αποτελέσματα δείχνουν ότι τα δύο μοντέλα ακολουθούν διαφορετικές μαθησιακές προσεγγίσεις, οι οποίες οδηγούν σε διακριτές αντιδράσεις στις προκλήσεις που χαρακτηρίζουν τις χρηματοοικονομικές χρονοσειρές. Οι αγορές συναλλάγματος διακρίνονται από υψηλή μεταβλητότητα, διαρθρωτικές αλλαγές και επιρροές οικονομικών, πολιτικών και συμπεριφορικών παραγόντων. Αποτελεσματικά μοντέλα πρόβλεψης πρέπει να διαχειρίζονται μεταβαλλόμενη μεταβλητότητα, αιφνίδια σοκ και μη σταθερά μοτίβα.

1. Διαφορές στη Συμπεριφορά των Μοντέλων

Το μοντέλο LSTM προσφέρει ένα σταθερό και προβλέψιμο σημείο αναφοράς. Αποδίδει καλά σε ομαλές, χαμηλής μεταβλητότητας χρονοσειρές, εντοπίζοντας βραχυπρόθεσμα μοτίβα και σταδιακές μεταβολές. Ωστόσο, όταν η μεταβλητότητα αυξάνεται ή όταν εμφανίζονται αιφνίδιες αλλαγές, οι αδυναμίες του γίνονται εμφανείς. Επειδή το LSTM βασίζεται αποκλειστικά στα μοτίβα που έμαθε κατά την εκπαίδευση, δυσκολεύεται να αντιμετωπίσει ακραία γεγονότα ή νέες συνθήκες που δεν έχει «δει» στο εκπαιδευτικό δείγμα.

Αντίθετα, το μοντέλο Lag-Llama παρουσιάζει ισχυρές δυνατότητες γενίκευσης ακόμη και χωρίς πρόσθετη εκπαίδευση στα δεδομένα συναλλάγματος. Η προεκπαίδευσή του σε ποικιλία χρονοσειρών το βοηθά να εντοπίζει μοτίβα αγοράς που ένα παραδοσιακό μοντέλο ενδέχεται να παραβλέπει. Το πλεονέκτημα αυτό αντανακλάται στη θετική απόδοσή του, παρά την απουσία εξειδικευμένης εκπαίδευσης στο εκάστοτε ζεύγος νομισμάτων.

2. Zero-Shot Απόδοση και ο Ρόλος του Fine-Tuning

Η διαδικασία fine-tuning δεν πραγματοποιήθηκε λόγω τεχνικών περιορισμών. Ωστόσο, η υφιστάμενη βιβλιογραφία και η θεωρητική θεμελίωση υποδεικνύουν ότι στοχευμένο fine-tuning θα μπορούσε να βελτιώσει την ακρίβεια και την προσαρμοστικότητα του μοντέλου. Παρά την απουσία fine-tuning, τα zero-shot αποτελέσματα δείχνουν ότι το Lag-Llama μπορεί

να ισοφαρίσει ή και να υπερβεί την απόδοση του LSTM σε αρκετά ζεύγη με μέτρια μεταβλητότητα.

Δεδομένης της ήδη ικανοποιητικής απόδοσης, το fine-tuning αναμένεται να ενισχύσει περαιτέρω την ικανότητα του μοντέλου να προσαρμόζεται σε πρόσφατες συνθήκες της αγοράς, αποτυπώνοντας καλύτερα βραχυπρόθεσμα μοτίβα και τοπικές δομές που η προεκπαίδευση ενδέχεται να μην καλύπτει πλήρως.

3. Επίδραση της Μεταβλητότητας και των Διαρθρωτικών Αλλαγών

Η συσσωμάτωση μεταβλητότητας, οι απότομες μεταβολές τιμών και οι διαρθρωτικές αλλαγές αποτελούν βασικά χαρακτηριστικά των χρονοσειρών συναλλάγματος.

- Το LSTM είναι ιδιαίτερα ευαίσθητο σε αυτές τις συνθήκες και συχνά παράγει αυξημένα σφάλματα σε περιόδους αναταραχής.
- Το zero-shot Lag-Llama διαχειρίζεται πιο αποτελεσματικά τέτοιες καταστάσεις, καθώς η προεκπαίδευσή του το έχει εκθέσει σε ποικιλία μοτίβων.
- Ωστόσο, το Lag-Llama αντιμετωπίζει και αυτό δυσκολίες σε ακραία, αιφνίδια γεγονότα, γεγονός που υπογραμμίζει τη δυσκολία πρόβλεψης σπάνιων αλλά ισχυρών μεταβολών.

Τα ευρήματα αυτά δείχνουν ότι τα foundation models διαθέτουν πλεονεκτήματα σε ασταθή περιβάλλοντα, αλλά παράλληλα επιβεβαιώνουν την εγγενή δυσκολία πρόβλεψης ακραίων γεγονότων.

4. Ικανότητα Γενίκευσης Μεταξύ Ζευγών Νομισμάτων

Ένα από τα βασικά συμπεράσματα της μελέτης είναι η ισχυρή ικανότητα γενίκευσης του Lag-Llama χωρίς ανάγκη επανεκπαίδευσης.

- Το μοντέλο μπορεί να παράγει αξιόπιστες προβλέψεις για πολλά διαφορετικά ζεύγη.
- Αντίθετα, το LSTM απαιτεί πλήρη εκπαίδευση για κάθε χρονοσειρά και δεν έχει δυνατότητα μεταφοράς γνώσης μεταξύ διαφορετικών περιουσιακών στοιχείων.

Το χαρακτηριστικό αυτό καθιστά το Lag-Llama ιδιαίτερα ελκυστικό για εφαρμογές μεγάλης κλίμακας, όπου η διατήρηση πολλαπλών μοντέλων είναι πρακτικά δύσκολη ή οικονομικά επιβαρυντική.

5. Πρακτικές Παράμετροι Εφαρμογής

Παρά την ισχυρή απόδοσή του, η πρακτική αξιοποίηση του Lag-Llama συνοδεύεται από τεχνικές απαιτήσεις. Η αποτελεσματική εφαρμογή του προϋποθέτει κατανόηση προχωρημένων εννοιών όπως:

- patching
- tokenization
- quantization
- επιτάχυνση μέσω GPU
- διαχείριση εξαρτήσεων και ρύθμιση περιβάλλοντος

Για αναλυτές ή επαγγελματίες χωρίς εμπειρία σε foundation models, οι παραδοσιακές προσεγγίσεις όπως το LSTM παραμένουν πιο προσιτές και εύκολες στην υλοποίηση, παρά τη χαμηλότερη ακρίβεια που προσφέρουν. Από τα παραπάνω προκύπτει ένα ουσιαστικό συμπέρασμα:

Το Lag-Llama είναι ένα ισχυρό μοντέλο, αλλά η αποτελεσματική αξιοποίησή του απαιτεί κατάλληλη υποδομή, εξειδικευμένη τεχνική γνώση και αναλυτική τεκμηρίωση.

6. Συνοπτική Επισκόπηση

Το LSTM αποδίδει καλά σε απλές, σταθερές χρονοσειρές, αλλά η ακρίβειά του μειώνεται σημαντικά σε ασταθή περιβάλλοντα. Το zero-shot Lag-Llama συχνά υπερτερεί του LSTM ακόμη και χωρίς εξειδικευμένη εκπαίδευση. Τα foundation models εμφανίζουν μεγαλύτερη ανθεκτικότητα σε αιφνίδιες αλλαγές και διαρθρωτικά σοκ. Το Lag-Llama παρουσιάζει ισχυρή γενίκευση σε διαφορετικές χρονοσειρές. Η πρακτική εφαρμογή του Lag-Llama απαιτεί περισσότερη τεχνική εξειδίκευση σε σχέση με το LSTM.

Συμπερασματικά, τα αποτελέσματα δείχνουν ότι τα foundation models όπως το Lag-Llama αποτελούν μια ισχυρή και πολλά υποσχόμενη επιλογή για την πρόβλεψη χρηματοοικονομικών χρονοσειρών. Ωστόσο, η πρακτική τους αξιοποίηση απαιτεί επαρκείς υπολογιστικούς πόρους και τεχνικές γνώσεις. Το επόμενο κεφάλαιο ολοκληρώνει τη μελέτη συνοψίζοντας τα βασικά σημεία και προτείνοντας κατευθύνσεις για μελλοντική έρευνα.

7 ΣΥΜΠΕΡΑΜΣΑΤΑ

Η παρούσα μελέτη συγκρίνει δύο μεθόδους πρόβλεψης χρηματοοικονομικών χρονοσειρών: το Long Short-Term Memory (LSTM), ένα ευρέως χρησιμοποιούμενο μοντέλο βαθιάς μάθησης, και το Lag-Llama, ένα σύγχρονο foundation model που έχει αναπτυχθεί ειδικά για αριθμητικά δεδομένα. Αξιοποιώντας ένα μεγάλο ιστορικό σύνολο δεδομένων συναλλαγματικών ισοτιμιών, μια αυστηρά σχεδιασμένη πειραματική διαδικασία και καθιερωμένες μετρικές αξιολόγησης, η μελέτη αξιολογεί συστηματικά την απόδοση κάθε μοντέλου τόσο σε σταθερές όσο και σε δυναμικές συνθήκες της αγοράς.

Τα αποτελέσματα δείχνουν ότι το LSTM αποδίδει αποτελεσματικά σε χρονοσειρές χαμηλής μεταβλητότητας, οι οποίες χαρακτηρίζονται από σταθερές διακυμάνσεις τιμών. Ωστόσο, η προγνωστική του ακρίβεια μειώνεται σε περιόδους αυξημένης μεταβλητότητας ή όταν εμφανίζονται μεταβολές της αγοράς που δεν έχουν παρατηρηθεί κατά την εκπαίδευση. Λόγω των περιορισμένων ικανοτήτων γενίκευσης και προσαρμογής του, το LSTM καθίσταται λιγότερο κατάλληλο για αγορές που εμφανίζουν έντονη δυναμική ή καταστάσεις υψηλής αβεβαιότητας.

Αντίθετα, το foundation model Lag-Llama επέδειξε ισχυρή και συνεπή απόδοση σε όλα τα σενάρια που εξετάστηκαν. Ακόμη και χωρίς πρόσθετη εκπαίδευση, παρήγαγε ιδιαίτερα ανταγωνιστικές προβλέψεις, αναδεικνύοντας τα οφέλη της μεγάλης κλίμακας προεκπαίδευσης σε ποικιλόμορφα σύνολα χρονοσειρών. Η ισχυρή του ικανότητα γενίκευσης του επιτρέπει να προβλέπει ακόμη και για ζεύγη νομισμάτων που δεν έχει «δει» προηγουμένως, μειώνοντας την ανάγκη εκπαίδευσης ξεχωριστών μοντέλων για κάθε χρονοσειρά. Προηγούμενη έρευνα καθώς και τα παρόντα ευρήματα υποδηλώνουν ότι η διαδικασία fine-tuning θα μπορούσε να ενισχύσει περαιτέρω την προσαρμοστικότητα και την ακρίβειά του, ειδικά σε περιόδους υψηλής μεταβλητότητας ή σημαντικών αλλαγών στις αγορές.

Παρά τα οφέλη του, το Lag-Llama συνοδεύεται από ορισμένες πρακτικές προκλήσεις. Τεχνικές όπως patching, tokenisation και quantisation, καθώς και η ανάγκη για εξειδικευμένα υπολογιστικά περιβάλλοντα, καθιστούν το μοντέλο δυσκολότερο στη χρήση για αρχάριους ή για αναλυτές χωρίς εμπειρία σε foundation models. Αντίθετα, το LSTM –αν και λιγότερο ακριβές– είναι πιο εύκολο στην εγκατάσταση, κατανόηση και προσαρμογή, ιδιαίτερα σε περιβάλλοντα με περιορισμένους πόρους ή τεχνικές δυνατότητες. Το γεγονός αυτό

υπογραμμίζει την ανάγκη για καλύτερη τεχνική υποστήριξη και εργαλεία, ώστε τα foundation models να γίνουν πιο πρακτικά και προσβάσιμα σε ευρύτερο κοινό.

Η συμβολή της μελέτης είναι σημαντική και πολυδιάστατη. Παρέχει μία από τις πρώτες άμεσες συγκρίσεις μεταξύ LSTM και Lag-Llama σε δεδομένα συναλλαγματικών ισοτιμών, αναδεικνύει τη σημασία της προεκπαίδευσης μεγάλης κλίμακας και της γενίκευσης στα foundation models, εξετάζει την απόδοσή τους σε ποικιλία ζευγών με διαφορετικά επίπεδα μεταβλητήτας και αποτυπώνει τα πρακτικά trade-offs μεταξύ ακρίβειας, προσαρμοστικότητας και ευχρηστίας. Τα αποτελέσματα καταδεικνύουν ότι τα foundation models μπορούν να βελτιώσουν σημαντικά την πρόβλεψη σε περιβάλλοντα αβεβαιότητας, όπως οι αγορές συναλλάγματος, εφόσον υπάρχουν επαρκείς υπολογιστικοί πόροι και τεχνική υποδομή.

Τα ευρήματα αυτά υποδεικνύουν διάφορες κατευθύνσεις για μελλοντική έρευνα, όπως η διερεύνηση προβλέψεων πολλαπλών βημάτων (multi-step forecasting), η αξιολόγηση μεγαλύτερων εκδόσεων του Lag-Llama ή άλλων foundation models για χρονοσειρές, η ενσωμάτωση εξωτερικών παραγόντων όπως μακροοικονομικοί δείκτες, η σύγκριση υβριδικών προσεγγίσεων και η ανάπτυξη εργαλείων που θα διευκολύνουν την υιοθέτηση των foundation models από επαγγελματίες του χρηματοοικονομικού κλάδου.

Κλείνοντας, η μελέτη αποδεικνύει ότι τα foundation models, όπως το Lag-Llama, αποτελούν μια πολλά υποσχόμενη προσέγγιση για την πρόβλεψη σύνθετων και εξελισσόμενων χρηματοοικονομικών χρονοσειρών. Αν και τα παραδοσιακά μοντέλα όπως το LSTM παραμένουν χρήσιμα σε απλούστερα σενάρια, η αυξημένη ακρίβεια, η προσαρμοστικότητα και η ικανότητα γενίκευσης των foundation models υποδεικνύουν ότι πιθανότατα θα αποτελέσουν βασικά εργαλεία στο μέλλον της χρηματοοικονομικής ανάλυσης και της αυτοματοποιημένης πρόβλεψης.

8 ΒΙΒΛΙΟΓΡΑΦΙΑ

- Brownlee, J. (2018). *Deep learning for time series forecasting: Predict the future with MLPs, CNNs and LSTMs in Python*. Machine Learning Mastery.
<https://machinelearningmastery.com/deep-learning-for-time-series-forecasting/>
- Elsworth, S., & Güttel, S. (2020). *Time series forecasting using LSTM networks: A symbolic approach*. arXiv. <https://arxiv.org/pdf/2003.05672>
- Gao, J., Cao, Q., & Chen, Y. (2024). *Auto-regressive moving diffusion models for time series forecasting*. arXiv.
<https://arxiv.org/pdf/2412.09328>
- Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2019). *LSTM: A search space odyssey*. arXiv.
<https://arxiv.org/pdf/1503.04069.pdf>
- Han, K., Han, K., Wu, H., Wu, L., Shi, Y., & Liu, C. (2024). Estimating treatment effects using observational data and experimental data with non-overlapping support. *Econometrics*, 12(3), 26.
<https://doi.org/10.3390/econometrics12030026>
- Liang, Y., Wen, H., Nie, Y., Jiang, Y., Jin, M., Song, D., Pan, S., & Wen, Q. (2024). Foundation models for time series analysis: A tutorial and survey. KDD '24.
<https://doi.org/10.1145/3637528.3671451>
- Lim, B., & Zohren, S. (2021). Time-series forecasting with deep learning: A survey. arXiv.
<https://arxiv.org/pdf/2004.13408.pdf>
- Lindemann, B., Müller, T., Vietz, H., Jazdi, N., & Weyrich, M. (2021). A survey on long short-term memory networks for time series prediction. *Procedia CIRP*, 99, 650–655. <https://doi.org/10.1016/j.procir.2021.03.088>
- Rasul, K., Ashok, A., Williams, A. R., Ghonia, H., Bhagwatkar, R., Khorasani, A., Darvishi Bayazi, M. J., Adamopoulos, G., Riachi, R., Hassen, N., Biloš, M., Garg, S., Schneider, A., Chapados, N., Drouin, A., Zantedeschi, V., Nevmyvaka, Y., &

Rish, I. (2024). Lag-Llama: Towards foundation models for probabilistic time series forecasting. arXiv.

[https://arxiv.org/pdf/2310.08278](https://arxiv.org/pdf/2310.08278.pdf)

Schuurman, D. (2020). On Kuyper and technology, or how a voice from the past can speak to our digital age. *Christian Scholar's Review*, 49(2), 161–174.

Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2020). *Financial time series forecasting with deep learning: A systematic literature review (2005–2019)*. arXiv.

[https://arxiv.org/pdf/1911.13228](https://arxiv.org/pdf/1911.13228.pdf)

The soundtracks of Australian transcultural cinema: Re-sounding the past. (2014).

<https://unswworks.unsw.edu.au/fapi/dataset/unswworks:12420/SOURCE02?view=true>

Wu, H., Xu, J., Wang, J., & Long, M. (2021). *Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting*. arXiv. <https://arxiv.org/pdf/2106.13008.pdf>

Zerveas, G., Jayaraman, S., Patel, D., Bhamidipaty, A., & Eickhoff, C. (2021). *A transformer-based framework for multivariate time series representation learning*. arXiv. <https://arxiv.org/pdf/2010.02803.pdf>

Zhou, T., Ma, Z., Wen, Q., Wang, X., Sun, L., & Jin, R. (2022). *FEDformer: Frequency enhanced decomposed transformer for long-term series forecasting*. arXiv. <https://arxiv.org/pdf/2201.12740.pdf>